

누구나 쉽게 이해하는 통계 & 이상 탐지 수학 가이드

한글 그래프 그림과 쉬운 설명으로 배우는 대표값, 산포도, 3-시그마 이상 탐지 및 브로드캐스팅

1. 대표값의 함정: 평균(Mean) vs 중앙값(Median)


📌 극단적인 이상치(Outlier)가 중심을 어떻게 왜곡하는가?

집단의 대표값을 정할 때 단순 '평균'만 보면 잘못된 판단을 할 수 있습니다.

📊 CEO 연봉의 착시 예시:

일반 직원 4명의 연봉이 3천만 원대인데, CEO 연봉이 10억 원이라면?

- **평균 (Mean):** 다 더해서 5로 나누면 **2억 2천6백만 원** → 일반 직원들의 실제 연봉과 너무 큼!
- **중앙값 (Median):** 순서대로 줄 세웠을 때 딱 한가운데 값인 **3천만 원** → 극단치에 흔들리지 않고 다수를 대표함!



2. 데이터의 요동침: 분산(Variance)과 표준편차(Standard Deviation)

📌 평균에서 얼마나 멀리 떨어져 흩어져 있는가?


두 반의 시험 평균 점수가 똑같이 80점이어도, 학생들의 실력 분포는 완전히 다를 수 있습니다.

지표	쉬운 계산 설명	특징 및 한계
분산 (Variance)	(각 값 - 평균)을 제곱해서 다 더한 후 평균 낸 값	음수를 없애려고 제곱을 하다 보니 단위가 점수 ² , °C ² 처럼 어색해짐
표준편차 (Std Dev)	분산에 제곱근(루트 √)을 씌워 원래 단위로 되돌린 값	"학생들 점수가 평균 80점에서 약 ±5점 범위에 모여 있다"고 바로 해석 가능

3. 과학적 이상 탐지: 3-시그마 (3-Sigma, 3σ) 규칙

📌 정상적인 기계 작동 범위와 고장 징후 구분하기

자연 현상이나 공장 설비의 정상 데이터는 대부분 종 모양의 '**정규분포**'를 따릅니다. 통계적으로 **평균에서 표준편차의 3배(3σ) 이상 벗어나는 데이터는 0.3% 미만**에 불과하므로, 이 구역에 들어오면 "이상 고장 징후!"로 판단합니다.



```
# 3-Sigma 법칙을 코드로 구현한 이상 탐지
mean_val = rpm.mean()
std_val = rpm.std()

# 정상 범위: [평균 - 3*std ~ 평균 + 3*std]
# 이 범위를 벗어나는 극단적 값만 필터링
anomalies = rpm[(rpm < mean_val - 3*std_val) | (rpm > mean_val + 3*std_val)]
```

4. 차원 자동 확장: 브로드캐스팅(Broadcasting) 원리

📌 도장 찍듯 작은 배열을 큰 배열 크기에 맞추기

NumPy는 크기가 다른 배열끼리 더하거나 뺄 때, **작은 배열을 복사하여 큰 배열 모양과 똑같이 도장 찍듯 확장**한 후 계산합니다.

🍷 도장 찍기 비유:

`2행 3열` 표 데이터에서 각 열의 기준값 `[70, 2.0]` (1행 3열)을 뺄 때, NumPy는 기준값을 아래로 1번 더 도장 찍어 `2행 3열` 표로 만들어 1:1로 빼줍니다.