

설비 고장을 예측하는 AI 데이터 분석

Pandas 집계·기초 통계

빈도와 그룹 집계

C O N T E N T S

목차

01 빈도 집계 — value_counts로 개수 세기, 구간으로 묶어 세기

02 그룹 집계 — 분할-적용-결합 구조, groupby 기본 사용법

01

빈도 집계

value_counts로 개수 세기, 구간으로 묶어 세기

이 단원의 실데이터 — 유압 시스템 상태 감시

그룹 집계를 연습할 데이터가 어떤 설비·범주로 이뤄졌는지 먼저 이해

공정 — 유압 시스템 상태 감시

유압 시스템이 60초 부하 사이클을 반복하며 압력·온도·진동을 측정한다. 각 사이클에는 냉각기·밸브·펌프의 상태와 운전 부하가 함께 기록된다.

핵심 범주와 연속 변수

범주형 = 냉각기상태(정상/저하/고장)·운전부하(고/저)·밸브상태(정상/경미/지연/심각). 연속형 = 온도·진동·압력·냉각효율. 검사결과는 합격/불합격.

정상과 이상

냉각기가 정상이면 온도 약 36°C, 저하 45°C, 고장이면 55°C로 상태별로 뚜렷이 갈린다. 그래서 상태(범주)로 묶으면 그룹 간 차이가 선명하게 드러난다.

왜 그룹 집계인가

냉각기·밸브·부하 같은 범주로 데이터를 나눠(groupby) 그룹별 평균·건수를 비교하면, 어느 상태에서 온도·진동이 위험한지 한눈에 파악할 수 있다.

행 하나하나 보기의 한계

1,500 행을 한 줄씩 읽는 대신 요약해 전체를 한눈에

행을 하나씩 읽는 대신 요약해 전체 파악

반도체 공정 데이터는 행이 1,500개 이상 — 눈으로 읽기엔 불가능한 규모

집계란 여러 값을 한 숫자로 압축

집계로 답할 수 있는 질문

빈도 · 그룹 비교 · 관계 — 오늘부터 배울 세 가지 핵심 질문

01 · 빈도

어떤 값이
가장 많은가

"저하이 요즘 이상하다"는 말의 첫 검증 단계

02 · 그룹 비교

그룹마다
평균이 다른가

라인·교대·설비별 차이를 보는 분석의 기본 단위

03 · 관계

두 값이 함께
움직이는가

온도와 진동, 두 측정값이 함께 움직이는지 확인

범주형과 수치형 데이터

셀 수 있는 데이터 구분이 먼저 — 설비 데이터는 두 종류가 섞여 있음

01 · 수치형

숫자로 측정, **평균·합계** 가능

온도 74.9도 — 더하거나 평균 낼 수 있는 측정값

02 · 범주형

종류로 구분, **빈도 집계** 대상

정상 · 정상 · 고장 — 종류를 나타내는 값

03 · 빈도란

각 종류가 **몇 번 나오는지**

범주형에서 빛을 발하는 첫 번째 집계

수치형과 범주형 비교

유형에 따라 쓸 수 있는 집계기가 달라짐 — 각 열의 유형 구분이 첫 습관

구분	수치형	범주형
예시	온도 · 진동	라인 · 결과
집계	평균 · 합계	빈도
빈도	구간 필요	바로 가능

범주형은 바로 빈도 가능 · 수치형은 구간으로 묶어야 의미를 가짐 — 다음 단계로 연결

value_counts로 개수 세기

한 열에 어떤 값이 **몇 번씩** 나오는지 자동으로 세는 도구

01 · 이름의 뜻

value(값)를 **counts**(센다) — 이름 그대로의 동작

02 · 사용법

세고 싶은 열을 고른 뒤 점을 찍고 붙이기

03 · 출력 정렬

가장 많은 종류부터 **자동 정렬**되어 출력

value_counts 기본 코드

한 열을 골라 점을 찍고 `value_counts` 붙이기

CODE

```
# 냉각기상태별 사이클 건수 세기
df["냉각기상태"].value_counts()
# 출력: 고장 40, 저하 40, 정상 40

# result 열의 정상·고장 건수 세기
df["result"].value_counts()
# 출력: 정상 67, 고장 53
```

개수를 비율로 바꾸기

개수 + 비율 — 둘을 함께 봐야 진짜 감이 잡힘

01 · 개수만의 한계

개수만으로는 많고 적음 판단 어려움

02 · 비율의 역할

전체에서 차지하는 **비율**로 봐야 비중이 보임

03 · 공정한 비교

규모가 다른 대상을 비교할 때 **필수**

normalize로 비율 구하기

value_counts에 `normalize=True` 옵션 추가

CODE

```
df["result"].value_counts(normalize=True).round(3)
# 출력:

# 정상 0.558
# 고장 0.442
# → 정상 약 55.8%, 고장 약 44.2%
```

normalize는 정규화의 뜻 — 전체를 1로 놓고 각 값의 몫으로 변환 · 함께 따라 칠 코드는

정렬과 결측값 옵션

기본 동작을 바꾸고 싶을 때만 쓰는 두 가지 옵션

`sort=False`

개수 순서 대신
데이터 등장 순서로 표시

등급 A·B·C·D처럼 정해진 순서로 비교할 때 유용

`dropna=False`

기본은 빈 값 무시
결측도 하나의 종류로 셈

빈 칸의 개수도 중요한 정보일 때 사용

value_counts 기본 동작 기억하기

옵션을 외우기 전에 — 기본 동작이 무엇인지 먼저

value_counts는 기본적으로 **많은 순서**로 정렬

기본적으로 **빈 값은 무시**하고 셈

기본 동작을 **바꾸고 싶을 때만** 옵션 사용

옵션은 한 번에 여러 개를 쉼표로 이어 쓸 수 있음

수치형을 구간으로 묶어 세기

먼저 묶고, 그 다음에 셈 — 순서가 핵심

STEP 1

pd.cut으로 구간 묶기

숫자를 정해진 경계에서 잘라 구간으로 묶음

예: 70도 미만 낮음 · 70~80 보통 · 80 이상 높음



STEP 2

value_counts 붙이기

만든 구간 데이터에 붙여 구간별 빈도 세기

구간 → 개수의 두 단계 흐름

pd.cut 구간 빈도 코드

구간으로 묶은 뒤 `value_counts`로 세기

CODE

```
band = pd.cut(df["온도"],  
bins=[0,40,50,200], labels=["낮음","보통","높음"])  
band.value_counts()  
# 출력: 낮음 41, 보통 40, 높음 39
```


실습 1. value_counts로 빈도 세기

한 열을 골라 value_counts로 값별 개수 세기

목표

한 열의 값별 개수를 세어 데이터 구성 파악

단계

- 설비 데이터를 불러와 앞부분과 구조 확인
- 설비 열에 value_counts를 붙여 값별 개수 세기
- 교대 열도 같은 방법으로 세어 가장 많은 값 확인

예상 결과

설비별·교대별 빈도표 출력 (심각 42건이 최다)

실습 2. 비율과 불균형 데이터

qc 합격·불합격 빈도와 비율로 불균형 확인

목표

합격·불합격 빈도와 비율을 구해 불균형 데이터 확인

단계

- 공정 데이터의 판정 열에 value_counts로 합격·불합격 개수 세기
- normalize 옵션으로 각 값의 비율을 소수로 확인
- round로 비율을 소수점 셋째 자리까지 정리

예상 결과

불합격이 전체 약 6%인 불균형 확인

불균형 데이터의 의미

실제 제조 현장의 불량품 데이터가 대부분 떠는 모습 — 빈도 확인이 함정 회피의 첫 단추

불합격은 전체의 약 **6%**, 합격이 압도적

무조건 합격이라 찍어도 약 **94%**는 맞히는 함정

빈도를 미리 확인하면 **이 함정을 피할 수 있음**

고장 예측 모델의 정확도에 속지 않으려면 — 빈도 확인이 첫 안전장치

실습 3. 구간으로 묶어 세기

pd.cut으로 수치형 값을 구간으로 묶어 빈도 세기

목표

수치형 센서 값을 구간으로 나눠 분포 확인

단계

- 진동 열의 최솟값과 최댓값으로 값의 범위 확인
- pd.cut으로 경계와 이름표를 정해 세 구간으로 묶기
- 묶은 구간에 value_counts로 구간별 빈도 세기

예상 결과

약함·보통·강함 구간별 빈도 출력 (보통 43건 최다)

02

그룹 집계

분할-적용-결합 구조, groupby 기본 사용법

그룹으로 나눠 보는 이유

전체 평균 하나로는 어느 라인이 문제인지 알 수 없음 — 그룹으로 나눠야 보임

전체 평균 하나로는 **그룹 사이의 차이**가 묻힘

의미 있는 그룹으로 나눈 뒤 **그룹마다 따로 집계**

문제가 집중된 곳을 빠르게 **찾아내는 도구**

얼음물·끓는물에 한 발씩 담근 사람의 평균 체감 온도가 '적당함'이라 나오는 이유

그룹 집계의 기준과 활용

그룹 기준 × 집계 대상 — 수많은 질문에 답할 수 있는 조합 구조

01 · 기준의 유형

그룹을 나누는 기준은 보통 범주형 데이터

02 · 흔한 기준

라인별 · 교대별 · 설비별로 나누는 방식

03 · 활용

기준과 집계 대상의 짝짓기 — 정비 우선순위 결정 근거

어느 라인 고장 비율이 높은지 · 어느 교대에 이상이 잦은지 — 정비 인력 투입의 근거

분할-적용-결합 구조

판다스의 그룹 집계는 항상 이 3단계로 작동



적용 단계의 계산만 알아 끼우면 평균·합계·최댓값 모두 구할 수 있음 — 분할은 그대로

3단계 한 줄로 압축

실제 코드에서 3단계가 한 줄에 — 분할이 줄 수, 적용이 숫자를 정함

01 · 분할

groupby

그룹을 나눔 — **결과의 줄 수**를 정함

그룹 3개면 3줄, 100개면 100줄

02 · 적용

mean · sum · max

각 그룹 계산 — **결과의 숫자**를 정함

함수 자리만 바꿔 평균·합계·최대

03 · 결합

자동 정리

그룹별 결과를 한 표로 **자동 정리**

코드는 똑같이 한 줄, 결과만 다름

groupby 기본 사용법

왼쪽에서 오른쪽으로 — 세 부분으로 끊어 읽기

01 · 그룹 기준 정하기

groupby 괄호 안에 — 줄을 나눌 열

02 · 집계할 열 고르기

[] 대괄호로 — 숫자로 답할 열

03 · 집계 함수 붙이기

.mean() 등 — 어떻게 계산할지

"df를 가지고, 냉각기상태으로 그룹을 나눈 뒤, 온도 열을 골라서, 평균을 내라" — 문장처럼 끊어 읽기

groupby 기본 코드

기준 → 열 → 함수 순서로 붙이기

CODE

```
df.groupby("냉각기상태")["온도"].mean().round(2)
# 출력:
# 냉각기상태
# 고장 54.67
# 저하 45.46
# 정상 35.89
```

고장이 가장 높음을 한 줄로 — 함수 자리에 mean 대신 sum, max, min, count도 가능

집계할 열 고르기

대괄호의 **겹 수**에 따라 결과 모양이 달라짐

01 · 한 열

`["온도"]`

대괄호 **한 겹** — 한 줄짜리 결과

Series 형태의 단일 측정값

02 · 여러 열

`[["온도", "vib"]]`

대괄호 **두 겹** — 표 형태 결과

여러 측정값을 한 번에 비교할 때

03 · 전체 열

`numeric_only=True`

열 생략 + 옵션 — **숫자 열만**

글자 열로 인한 오류 방지

대괄호 한 겹과 두 겹

이 차이를 헛갈리면 **결과 모양**이 달라짐

대괄호 **한 겹**은 열 하나, 결과는 한 줄 목록

대괄호 **두 겹**은 열 여러 개, 결과는 표

분석 목적에 맞는 **열 한두 개만** 골라 집계

모든 열을 한꺼번에 보면 핵심을 놓치기 쉬움 — 한두 개에 집중

여러 기준으로 그룹 묶기

정상 거부하처럼 — 더 잘게 나눠 보기

01 · 여러 기준 묶기

그룹 기준 **두 개 이상**을 대괄호로 묶기

02 · 더 세밀한 그룹

기준들을 **조합**한 세밀한 그룹 생성

03 · 순서가 관점

기준 **순서**에 따라 보는 관점이 달라짐

여러 키 그룹 코드

기준 여러 개를 **대괄호**로 묶기

CODE

```
df.groupby(["냉각기상태", "운전부하"])["온도"].mean().round(2)
# 출력 (일부):
# 고장 고부하 55.51
# 고장 저부하 54.05
# 저하 고부하 44.07
# 정상 고부하 35.89
```

고장 전체가 높는데 그중 저부하가 더 높음 — 세밀한 관찰이 이상 징후 단서

그룹 결과 정렬과 해석

그룹 결과에 `sort_values`를 이어 — 우선순위가 보이게

01 · 이어 붙이기

`groupby` 결과에 `.sort_values()` 이어 붙여 값 크기로 정렬

02 · 내림차순

`ascending=False`로 큰 값부터 내림차순

03 · 우선순위

정렬은 어디부터 살펴볼지 우선순위를 정해 줌

정렬 해석할 때 주의

정렬은 우선순위만 알려줌 — 결론은 숫자 + 맥락으로 함께

정렬 맨 위가 **항상 나쁜 것은 아님**

차이가 **의미 있는 차이**인지 함께 판단

정렬은 어디를 볼지 알려줄 뿐 — 왜 그런지는 **현장 지식**으로

고장 35.89 vs 정상 54.67의 차이 약 3도 — 우연인지 점검할 거리인지는 추가 분석

size와 count 차이

핵심 차이는 **결측값 처리**

구분	size	count
대상	전체 행	비결측 값
결측값	포함	제외
열 선택	불필요	필요

빈 칸이 없으면 둘이 같음 · 결측이 있는 반도체 데이터에서는 결과가 달라짐

size와 count 활용하기

둘의 차이가 데이터의 **구멍**을 보여줌

01 · 차이가 알려주는 것

size와 count가 **크게 차이** = 그 그룹에 빠진 값 多

02 · 단서

측정 누락이 잦은 라인이나 설비를 찾는 단서

03 · 모르고 쓰면 위험

빠진 데이터를 모르고 평균 내면 결과 왜곡

실습 4. groupby로 그룹 집계

기준 → 열 → 함수 순으로 그룹별 통계 구하기

목표

기준 열로 그룹을 나눠 그룹별 통계 구하기

단계

- 라인으로 그룹을 나눠 압력 열의 평균 집계
- 집계 함수를 바꿔 설비별 최고 온도 확인
- size로 교대별 측정 건수까지 확인

예상 결과

라인별 평균 압력.설비별 최고 온도.교대별 건수 출력

실습 5. 그룹별 평균 비교와 정렬

그룹별 평균을 구해 정렬로 두드러진 그룹 찾기

목표

그룹별 평균을 구하고 정렬해 두드러진 그룹 찾기

단계

- 설비로 그룹을 나눠 진동 평균 집계
- 집계 결과에 정렬을 이어 붙여 내림차순으로 정렬
- 가장 진동이 큰 설비를 맨 위에서 확인

예상 결과

진동 평균이 큰 설비 순 정렬 (정상 최대)

실습 6. 여러 기준 조합 그룹

두 기준을 묶어 세분 그룹의 평균과 건수 확인

목표

두 기준을 조합해 단일 기준에서 안 보이던 패턴 찾기

단계

- 라인과 교대 두 기준을 묶어 진동 평균 집계
- 같은 두 기준으로 size를 구해 조합별 측정 건수 확인
- 건수가 적은 조합의 평균은 신중히 해석

예상 결과

라인x교대 조합별 진동 평균과 건수 출력

실습 7. 빈도와 그룹 집계 종합

빈도 집계와 그룹 집계를 한 흐름으로 연결

목표

빈도 집계와 그룹 집계를 한 흐름으로 연결해 분석

단계

- value_counts로 설비 구성과 정상·고장 비율 파악
- 고장 행만 걸러 라인별 고장 건수 집계
- groupby로 설비별 온도·진동 평균까지 비교

예상 결과

구성·비율·라인별 고장 건수·설비별 평균 출력

실습 — 종합 산출물

세 문장으로 정리 — 다음 시간 리포트의 기초

01 · 전체 빈도

전체 빈도에서
알게 된 것 1가지

예: "불합격은 전체의 약 6%, 합격이 압도적"

02 · 그룹 비교

그룹 비교에서
알게 된 것 1가지

예: "고장 저부하이 다른 조합보다 평균 온도
약 3도 높음"

03 · 더 볼 것

더 살펴봐야 할 그룹
1가지와 이유

다음 분석의 출발점 — 가설을 다음 단계로

다음 시간에서는 — 그룹별 비교를 평균을 넘어 분산·표준편차까지 확장