

# 설비 고장을 예측하는 AI 데이터 분석

Pandas 집계·기초 통계

그룹별 통계량

posco

C O N T E N T S

# 목차

---

01      **대푯값과 흠어짐**      평균이 알려주는 대푯값 · 표준편차로 단위 되돌리기

---

02      **여러 통계 정리**      agg로 여러 통계 한 번에 · 평균과 표준편차 함께 읽기

---

---

# 01

## 대폿값과 흠어짐

평균이 알려주는 대폿값 · 표준편차로 단위 되돌리기

# 이 단원의 실데이터 — 유압 시스템 상태 감시

그룹별 통계량을 낼 데이터가 어떤 범주로 이뤄졌는지 먼저 이해

## 공정 — 유압 시스템 상태 감시

유압 시스템이 60초 부하 사이클을 반복하며 온도·진동·압력을 측정한다. 각 사이클엔 냉각기·밸브 상태와 운전 부하가 함께 기록된다.

## 핵심 범주와 연속 변수

범주형 = 냉각기상태·운전부하·밸브상태. 연속형 = 온도·진동·압력. 그룹별로 평균뿐 아니라 분산·표준편차(흩어짐)를 함께 봐야 안정성이 드러난다.

## 정상과 이상

냉각기 정상이면 온도가 36°C 부근에 촘촘히(표준편차 0.4) 모이지만, 고장이면 평균 55°C에 흩어짐도 커진다(표준편차 3.8). 평균과 흩어짐을 함께 봐야 한다.

## 왜 그룹별 통계인가

상태별 평균·분산·min·max를 agg로 한 표에 모으면, 어느 상태가 높고(수준) 얼마나 불안정한지(흩어짐)를 한눈에 진단할 수 있다.

# 평균이 알려주는 대푯값

평균은 흠어진 수많은 값을 하나의 숫자로 압축한 **대푯값**

## 01 · 정의

여러 값을 하나로 대표하는  
**대푯값**

데이터 전체를 한 숫자로 요약해 비교의 기준으로 사용

## 02 · 압축

흠어진 수많은 값을  
**한 숫자로 압축**

수십·수백 개의 측정값을 평균 하나로 요약해 한눈에 비교



## 평균이라는 대푯값

평균은 모든 값을 **골고루** 반영 — 실제로 존재하지 않는 값일 수도 있음

### 라인별 평균 온도

A 라인

54.67

A 라인 측정값 평균 (°C)

B 라인

45.46

B 라인 측정값 평균 (°C)

C 라인 · 최고

35.89

C 라인 측정값 평균 (°C) — 가장 뜨거움

가족 평균 2.5명에 2.5명인 가족은 없음 — 평균은 데이터를 요약한 가상의 기준점

## 평균만 보면 놓치는 것

평균이 같아도 **흠어진 정도**는 완전히 다를 수 있음

두 라인의 평균이 똑같이 78도라면  
두 라인은 **같은 상태**일까?

답

**아니다**

평균은 가운데가 어디쯤인가만 알려줄 뿐 퍼짐은 모름

위험 신호

**평균 정상 + 들쭉날쭉**

설비 안전에서는 평균이 정상이어도 흔들리면 위험 신호일 수 있음

# 평균 같아도 흠어짐은 다르다

평균은 똑같이 78도 — 그런데 실제 데이터는 전혀 다른 모습

| 구분    | 설비 가      | 설비 나      |
|-------|-----------|-----------|
| 평균 온도 | 78도       | 78도       |
| 측정 범위 | 76 ~ 80도  | 50 ~ 105도 |
| 흠어짐   | ✔ 작음 — 안정 | ✖ 큼 — 불안정 |

평균만 보고 같다고 판단하면 큰 실수 — 설비 나 는 온도가 요동쳐서 고장 위험이 훨씬 높음



## 분산으로 흠어짐 재기

분산은 데이터가 평균에서 얼마나 흠어졌는지 나타내는 값

### 01 · 정의

분산이란 무엇인가

평균에서 떨어진  
거리의 제곱 평균

각 값이 평균에서 얼마나 떨어져 있는지 모아  
서 평균낸 값

### 02 · 왜 제곱?

제곱하는 이유

음수와 양수가  
서로 상쇄되는 것 방지

그냥 더하면 평균보다 큰 값과 작은 값이 상쇄  
되어 0

### 03 · 해석

분산이 크면 / 작으면

크면 들쭉날쭉,  
작으면 평균 근처

값이 평균에서 멀리 퍼지면 분산이 커지고 모  
이면 작아짐

## 분산 구하기 코드

**var** 함수로 라인별 분산 구하기 — variance의 줄임말

### CODE

```
df.groupby("냉각기상태")["온도"].var().round(2)
# 출력:
# 고장 14.13
# 저하 2.15
# 정상 0.13
```

**저하 2.15** 가장 안정 · **고장 0.13** 가장 들쭉날쭉

다만 분산은 거리를 제공했기에 단위도 제공 — 도제공은 직관적이지 않음

함께 따라 칠 코드:

## 표준편차 구하기 코드

**std** 함수로 원래 단위의 흩어짐 구하기 — 분산에 제곱근을 씌운 값

### CODE

```
df.groupby("냉각기상태")["온도"].std().round(2)
# 출력:
# 고장 3.76
# 저하 1.47
# 정상 0.36
```

**정상 3.76은 도 단위라 바로 해석** — 평균에서 평균적으로 약 10도 떨어져 있음  
분산 14.13에 제곱근 = 3.76 — 분산과 표준편차는 동전의 양면

함께 따라 칠 코드:

# 분산과 표준편차 비교

결정적 차이는 단위 — 둘 중 하나만 외운다면 표준편차

| 구분 | 분산 var   | 표준편차 std |
|----|----------|----------|
| 의미 | 흠어짐 정도   | 흠어짐 정도   |
| 단위 | ✗ 단위의 제곱 | ✓ 원래 단위  |
| 관계 | std의 제곱  | var의 제곱근 |

실무에서는 표준편차를 훨씬 많이 사용 — 단위가 원래 데이터와 같아 바로 해석되기 때문

## 설비 상태 4분면

평균과 표준편차를 **한 쌍으로 묶어** 설비 데이터를 진단하는 사고 틀

### 01 · 이상적 안정

#### 평균 정상 + 편차 작음

적절한 온도에서 안정적으로 돌아가는 가장 이상적인 상태

### 02 · 불안정 주의

#### 평균 정상 + 편차 큼

평균은 괜찮아 보여도 온도가 들쭉날쭉 요동치는 불안정 신호

### 03 · 일관된 과부하

#### 평균 높음 + 편차 작음

꾸준히 높은 온도로 안정적으로 운영 — 과부하 상태 의심

### 04 · 고위험

#### 평균 높음 + 편차 큼

뜨거운데다 불안정하기까지 한, 가장 위험한 상태

설비 진단의 황금 규칙 — 평균과 표준편차는 항상 한 쌍으로



## 실제 라인에 적용하기

평균만 봤다면 A·B가 비슷 — 표준편차를 보니 B가 더 안정적이라는 결론

### A 라인

보통 안정성

평균

54.67

표준편차

3.76

B와 평균 약 1도 차이 — 거의 비슷

### B 라인 · 가장 안정

가장 안정적

평균

45.46

표준편차

1.47

A보다 표준편차 훨씬 작음 — 가장 안정

### C 라인 · 주의

가장 불안정

평균

35.89

표준편차

0.36

뜨거우면서 불안정 — 가장 주의 필요

평균만 봤을 때와 평균+표준편차를 함께 봤을 때 판단이 달라지는 그룹을 찾는 것이 핵심

## 최소·최대·개수 집계

평균·표준편차 다음으로 자주 쓰는 **기본 통계 3종**

### 01 · 최솟값 min

가장 작은 값

**데이터의  
가장 작은 값**

데이터의 한쪽 끝 — 이상값 가능성 점검

함수: **min**

### 02 · 최댓값 max

가장 큰 값

**데이터의  
가장 큰 값**

고장 113.4도처럼 평균보다 훨씬 높으면 과열  
사건 의심

함수: **max**

### 03 · 개수 count

측정의 신뢰도

**결측 땀  
실제 값의 수**

5번 측정과 500번 측정의 평균은 신뢰도가 다름

함수: **count**

## 양 끝값의 의미

양 끝값은 **이상값**일 가능성 — 데이터 받으면 가장 먼저 훑기

### 01 · 양 끝의 자리

이상값 가능성

양 끝에 있는 만큼  
**이상값 가능성 높음**

데이터의 양 끝은 정상 범위를 벗어났을 확률  
이 큼

### 02 · 의심 신호

측정 오류 vs 진짜 사건

측정 오류인지  
**설비 이상 신호**인지

고장 최댓값 113.4도 — 평균보다 훨씬 높다면  
따져 볼 가치

### 03 · 점검 절차

품질 확인의 첫 단계

먼저 훑어  
**이상한 값 거르기**

온도 음수·압력 비현실 등 입력 오류 가능성 점검



## 중앙값과 평균의 차이

중앙값은 크기 순으로 줄 세웠을 때 한가운데 값

| 구분  | 특징           |                                                                                                  |
|-----|--------------|--------------------------------------------------------------------------------------------------|
| 평균  | 극단값에 끌려감     | <p>예시 · 직원 9명 + 사장 1명 월급</p> <p>사장이 어마어마하게 받으면<br/>평균은 <b>확 올라감</b>,<br/>중앙값은 <b>흔들리지 않음</b></p> |
| 중앙값 | 극단값에 흔들리지 않음 |                                                                                                  |

### 평균과 중앙값이 벌어지면 — 치우침이나 극단값의 신호

두 값이 비슷하면 데이터가 고른 상태

두 값 비교만으로도 치우침을 진단할 수 있는 유용한 도구

## 평균과 중앙값 코드

`median`과 `mean`을 함께 구해 두 값의 차이로 치우침 진단

### CODE

```
df.groupby("냉각기상태")["온도"].median().round(2)
# 출력: 고장 55.45, 저하 44.9, 정상 35.9
# 평균: 고장 54.67, 저하 45.46, 정상 35.89
```

**저하 평균 45.46 ↔ 중앙값 44.9 — 약 2도 차이**

평균을 끌어내리는 낮은 온도 측정값이 일부 있다는 신호

함께 따라 칠 코드:

---

# 02

## 여러 통계 정리

agg로 여러 통계 한 번에 · 평균과 표준편차 함께 읽기

## agg로 여러 통계 한 번에

**agg** — aggregate, 여러 통계를 한 번에 구해 표로 정리

### 01 · 사용법

한 번에 여러 통계

**여러 통계를  
한 번에 구해 표로**

평균·표준편차·최댓값을 매번 따로 치는 번거  
로움 해소

### 02 · 전달 방법

이름을 목록으로

**통계 이름을  
목록으로 묶어 전달**

따옴표로 감싼 통계 이름을 리스트로 넘기면  
모든 그룹에 동일 계산

### 03 · 조합

자유로운 통계 선택

**mean · std · var  
max · min · median · count  
자유 조합**

필요한 통계 묶음만 골라 한 표에 정리

## agg 리스트 방식 코드

통계 이름을 **목록**으로 묶어 전달 — 라인이 행, 통계가 열인 표

### CODE

```
df.groupby("냉각기상태")["온도"].agg(["mean", "std", "max"]).round(2)
# 출력:
#      mean  std  max
# 고장 54.67 3.76 57.8
# 정상 35.89 0.36 36.4
```

**통계 세 개를 한 표에 담은 결과** — 따로따로 짜맞추던 것에 비해 훨씬 효율적  
다만 결과 열 이름이 영어로 나와서 보고서에 쓰기엔 친절하지 않음

함께 따라 칠 코드:



## agg 이름 붙이기 코드

결과이름 = (원본열, 통계) 형태로 정리 — named aggregation

### CODE

```
df.groupby("냉각기상태").agg(  
    평균온도=("온도", "mean"),  
    온도편차=("온도", "std"),  
    측정수=("온도", "count"),  
).round(2)
```

등호 왼쪽 = 결과 열 이름(우리말 자유) · 등호 오른쪽 = (원본 열, 통계 이름)  
여러 열의 다양한 통계를 한 표로 정리하는 **가장 깔끔한 방법**

함께 따라 칠 코드:

## 이름 붙이기 방식을 권장하는 이유

named aggregation은 최신 판다스의 **권장 문법**

### 01 · 권장

최신 판다스의 표준

**판다스가 공식으로  
권장하는 안전한 방법**

버전이 올라가도 사라지지 않고 그대로 작동

### 02 · 옛날 방식 주의

딕셔너리 방식

**옛날 중괄호 방식은  
일부 제거됨**

인터넷의 옛날 코드에 중괄호가 보여도 따라  
하지 말기

### 03 · 결론

버전 문제 없이

**처음부터 권장 방식으로  
익혀 두기**

이름 등호 괄호 방식이 현재 표준이자 미래의  
표준

## 실습 1. 평균·분산·표준편차 구하기

전체와 라인별로 평균·분산·표준편차 구하기

### 목표

대푯값과 흩어짐을 나타내는 세 통계량 구하기

### 단계

- 진동 열 전체의 평균·분산·표준편차를 각각 구하기
- 표준편차를 제공하면 분산과 같아지는지 확인
- 라인으로 그룹을 나눠 라인별 평균과 표준편차 비교

### 예상 결과

전체 통계와 라인별 평균·표준편차 출력 (표준편차<sup>2</sup>=분산)



## 실습 2. 그룹별 통계 응용

qc 합격·불합격 그룹별 지표 통계 비교

### 목표

합격·불합격 그룹의 지표 평균과 표준편차 비교

### 단계

- 판정 열로 그룹을 나눠 주요 지표들의 평균 집계
- 같은 그룹 기준으로 표준편차를 구해 흠어짐 비교
- 두 그룹의 통계 차이를 읽어 불량률의 특징 관찰

### 예상 결과

합격·불합격별 지표 평균·표준편차 표 출력

## 실습 3. agg로 여러 통계 한 번에

리스트.이름붙이기 두 방식으로 여러 통계 요약

### 목표

한 번의 agg로 여러 통계를 동시에 구하기

### 단계

- 교대로 그룹을 나눠 진동의 평균·표준편차·최댓값을 리스트로 한 번에
- 이름 붙이기 방식으로 설비별 평균온도·평균진동·측정수 요약
- 두 방식의 결과 표 모양 비교

### 예상 결과

리스트 방식 표와 이름 붙인 요약표 출력

## 실습 4. agg 진단표 만들기

이름 붙인 agg로 설비 진단표를 만들고 정렬

### 목표

여러 통계를 담은 진단표를 만들고 정렬해 우선순위 파악

### 단계

- 설비로 그룹을 나눠 측정수·평균온도·온도편차·평균진동·평균압력을 이름 붙여 집계
- 온도편차를 기준으로 내림차순 정렬
- 편차가 큰 설비를 불안정 후보로 확인

### 예상 결과

설비별 진단표가 온도편차 큰 순으로 정렬 (지연 최대)

## 실습 5. 그룹별 통계량 종합

전체·그룹 통계와 진단표를 한 흐름으로

### 목표

전체 통계부터 그룹 진단표까지 한 흐름으로 종합

### 단계

- 온도 열의 전체 평균과 표준편차로 기준선 파악
- 라인별 평균과 중앙값을 함께 구해 치우침 확인
- 설비 진단표를 온도편차 순으로 정렬해 우선 점검 대상 선정

### 예상 결과

전체 기준선·라인 치우침·진단표 정렬 결과 출력

## 실습 — 종합 산출물

한 페이지 분량의 통계 요약은 네 항목으로 작성

### 01 · 전반 상태

#### 전체 통계로 본 데이터 상태 1문장

전체 평균·표준편차로 종합 상태를 요약한 한 문장

### 02 · 핵심 차이

#### 그룹 비교에서 발견한 차이 1가지

라인별 비교에서 가장 두드러진 차이를 한 문장으로

### 03 · 주의 그룹

#### 평균-편차로 본 주의 그룹과 근거

가장 먼저 점검할 그룹과 그 판단의 근거를 한 문장으로

### 04 · 추가 분석

#### 더 살펴봐야 할 항목 1가지

다음 분석으로 이어질 후속 질문 — 통합 리포트로 연결

평균은 중심을, 표준편차는 흔들림을 — 둘을 함께 봐야 설비 상태가 제대로 보임