

설비 고장을 예측하는 AI 데이터 분석

결측치 처리

결측치 이해와 확인

C O N T E N T S

목차

01 **결측치 이해와 확인** 결측치란 무엇인가, 위장된 결측치, 결측치 확인 방법

02 **결측치 제거와 대체** 결측치 제거, 결측치 대체, 처리 워크플로우

01

결측치 이해와 확인

결측치란 무엇인가 · 위장된 결측치 · 결측치 확인 방법

데이터 전처리란 무엇인가

분석 시간의 70~80%, 전처리에 투입되는 일

01 · 비중

분석 업무의 **70~80%**
전처리에 쓰이는 시간

멋진 모델 이전에 데이터를 깨끗하게 다듬는
손질이 먼저

02 · 현실

현장 데이터는
비거나 잘못된 값이 많음

센서 고장, 입력 실수 — 쓰레기를 넣으면 쓰레
기가 나오는 구조

03 · 첫 단추

전처리의 시작은
결측치 다루기

재료 손질이 부실하면 아무리 멋진 요리도 못
먹는 일과 같음

결측치란 무엇인가

Missing Value — 데이터 표에서 값이 비어 있는 칸

01 · 정의

데이터 표에서
값이 비어 있는 칸

엑셀 표에서 어떤 칸엔 값이, 어떤 칸엔 아무것도 없는 그 빈 칸

02 · 컴퓨터의 반응

빈 칸을 만나면
계산이 멈추거나 에러

사람은 그냥 넘어가지만 컴퓨터는 평균을 내다가도 죽음

03 · 제조 데이터

센서가 많아
결측이 특히 흔함

설비에는 센서가 수백 개씩 붙어 빈 칸이 자주 발생

NaN의 정체

Not a Number — 판다스가 붙여 두는 "값 없음" 뜻말

01 · 의미

Not a Number
숫자가 아님

빈 칸을 발견한 판다스가 자동으로 찍는 결측
표시

02 · 0으로 채우면

온도 0도와
기록 없음은 다른 일

빈 칸을 0으로 메우면 컴퓨터가 진짜 숫자 0으
로 오해

03 · 전염성

NaN이 끼면
결과까지 NaN

잉크 한 방울이 깨끗한 물을 흐리게 만드는 것
과 같음

NaN과 None의 차이

이름은 둘이지만 판다스에선 똑같이 결측으로 잡힘

Q 1. **None은 무엇인가요?**

A. 순수 파이썬 자체의 빈 값. "아무것도 없음"을 나타내는 파이썬 기본 표현

Q 2. **NaN은 무엇인가요?**

A. 데이터 표 속 빈 숫자값. 판다스 같은 데이터 도구에서 숫자 칸이 비었을 때 쓰는 표시

Q 3. **둘을 구분해야 하나요?**

A. 판다스가 둘 다 결측으로 처리하니 괜찮음. 실무에서 자주 보는 건 NaN

결측치가 표에 보이는 모습

csv에선 빈 칸, 판다스에선 NaN — 도구마다 옷만 다를 뿐 속은 같음

csv 파일을 메모장으로 열면 결측 자리는 **그냥 빈 칸**으로 보임

그 파일을 판다스로 불러오는 순간 빈 칸이 **NaN으로 바뀌는 일**

실전에서는 앞부분 몇 줄만 띄워 빠르게 살피지만, 앞쪽에 NaN이 없다고 결측이 없다고 단정 금지

→ **눈으로 보는 확인과 숫자로 세는 확인을 늘 함께**

측정시각	온도	압력	진동
10:00	25.3	1.02	2.4
10:01	NaN	1.05	2.5
10:02	25.7	NaN	2.6
10:03	26.1	1.04	NaN
10:04	NaN	1.06	2.7
10:05	26.4	1.03	2.5

센서 고장과 결측

"왜 값이 빠졌을까" — 이유를 알면 채울지 지울지 판단이 쉽

01 · 고장

센서가 망가지면
그 순간 값이 빔

설비 부품인 만큼 언제든 고장 — 기록이 끊김

02 · 점검·교체

센서를 떼면
기록이 끊기는 구간

잠깐 점검은 앞뒤 값으로 채우는 게 자연스러움

03 · 환경

먼지·고온으로
일시적 측정 실패

통째로 고장 난 컬럼은 빼는 선택지가 합리적

수집·전송 과정의 결측

센서가 멀쩡해도 통신·합치기·옮기기 어디서든 결측 발생

01 · 통신 끊김

통신이 끊기면
그 사이 값이 사라짐

센서 → 통신선 → 중간 서버 → 저장 어디서든
문제 발생

02 · 합치기·변환

표를 합칠 때
시점이 안 맞아 빔

1분 단위 + 5분 단위 합치면 시점 맞추는 과정
에서 빈 칸 발생

03 · 자연스러운 현상

결측은
현실 데이터의 일상

데이터가 잘못된 게 아니라 발견·처리하는 능
력의 문제

위장된 결측치 — 숫자 0

멀쩡한 숫자인 척 숨어 있는 결측 — 대표 선수는 0

01 · 의심

가동 중인데
압력이 0 → 위장 결측

가동 중인 설비 압력이 진짜 0일 수 없음 — 센서가 못 읽은 신호

02 · 정상

멈춘 설비의
속도 0 → 진짜 값

똑같은 0이라도 어떤 건 결측, 어떤 건 정상

03 · 판단

0의 의미는
사람이 맥락으로

컴퓨터가 못 가리는 일 — 데이터의 의미를 아는 사람의 몫

위장된 결측치 — 센티넬 값

999, 9999 — 약속된 결측 표시, Sentinel

01 · SENTINEL VALUE

현실에 없는 값을 정해두고
"값 없음" 자리에 넣기로 한 약속

온도 **-999도**는 현실에 없는 값

옛날 시스템은 빈 칸을 저장할 방법이 없어서 이런 약속을 사용

데이터의 **최솟값**·**최댓값**을 보면 발견 가능

02 · 방치 시 영향

그대로 두면
평균이 크게 망가짐

컴퓨터는 -999를 진짜 숫자로 받아들임

진동값에 -999가 섞이면 평균이 **음수로 폭락**

불러올 때 **결측으로 인식시켜 줘야 함**

빈 문자열과 공백도 결측

글자 컬럼에서도 결측은 일어남 — "비어 보이는 모든 것을 의심"

01 · 빈 문자열

글자 칸에
아무것도 없는 상태

설비명·작업자 이름 같은 텍스트 컬럼에서 발생

02 · 공백

스페이스만 들어가
판다스가 못 잡기도

공백을 정상값으로 취급해 결측으로 안 잡는 함정

03 · 원칙

비어 보이는
모든 것을 의심

NaN, 빈 칸, 0, -999, 공백 — 여러 얼굴의 결측

결측치와 데이터 타입

정수가 갑자기 소수로 보이면 —거기 **결측이 끼었다는 신호**

원래 입력

1, 2, 3

NaN이 끼면

1.0, 2.0, 3.0

NaN이 기술적으로 실수형 —정수 컬럼 전체가 자동으로 실수형으로 변환

분명 정수를 넣었는데 **1.0, 2.0, 3.0**으로 보이는 일

오류가 아닌 **정상 동작**

→ **결측 의심의 단서**로 활용

처리 후 다시 **정수형으로 복원** 가능 (`astype("int")`)

NaN의 비교 연산 함정

NaN은 자기 자신과 비교해도 **"다르다"**고 나오는 별난 값

01 · 잘못된 방법

```
df["온도"] == NaN
```

결과는 항상 거짓 → 분명 빈 칸인데 **결측 0개**로 나옴

값 없는 것과 값 없는 것이 같다고 단정하기 어색

그래서 NaN은 등호로 비교 불가

초보가 가장 자주 당하는 함정 — "결측 0개"라는 오해

→ 결측은 반드시 **isna** 같은 전용 도구로

02 · 올바른 방법

```
df["온도"].isna()
```

결측 방치 시 통계 왜곡

"결측 빼고 계산"이 만드는 침묵의 오차 — 그리고 위장 결측의 폭주

01 · 평균 왜곡

10개 중 2개가 결측이면
8개 평균이 됨

빠진 2개가 유난히 높았다면 실제보다 낮게 보임
→ 설비 상태 오판

02 · 위장 결측

999 방치 시
평균이 음수로 폭락

정상값 2~4 사이인데 진동 평균이 음수 — 완전히 틀린 판단

03 · 전 통계 영향

합계·표준편차도
함께 흔들림

평균뿐 아니라 거의 모든 통계에서 왜곡 발생

결측 방치 시 시각화·모델 문제

그래프는 끊기고, 모델은 학습조차 시작 못 함 — 분석의 기초 공사

01 · 그래프

선이 뚝 끊기거나
점이 들텔뎡

시간에 따른 온도 변화선이 중간에 결측을 만나면 끊김

02 · 모델

학습 시작조차 못 하고
에러로 중단

대부분 머신러닝 도구는 빈 칸을 거부 — 엉성하게 채우면 가짜를 진짜로 학습

03 · 결론

결측 처리는
모든 분석의 기초

통계·시각화·모델 — 어떤 분석을 하든 통과해야 할 관문

결측이 타깃 컬럼에 있을 때

입력값 결측과 정답(Target) 결측은 처리 방식이 다름

01 · 입력값 결측

평균·앞뒤값으로
채워 활용 가능

온도·압력·진동 같은 입력 정보가 비면 채워서
살리기

02 · 정답 결측

추측으로 채우면
모델이 잘못 배움

가짜 정답을 가르치면 모델이 틀린 걸 외워 버림

03 · 원칙

정답이 빈 행은
채우지 말고 제거

센서값 결측 ≠ 정답 결측 — 처리 방식을 분리

결측치 처리의 큰 그림

확인 → 판단 → 처리 — 의사가 진찰·치료방침·처방을 내리는 흐름과 같음

01 · 확인

**결측이 어디에 얼마나
있는지 파악**

어디가 아픈지도 모르고 약부터 먹는 일을 피함

02 · 판단

**제거할지 대체할지
결정**

너무 많은 컬럼은 빼고, 몇 개 안 되면 채워 살림 — 가장 사람다운 단계

03 · 처리

**실제로 제거·대체
그리고 재확인**

이번 모듈은 첫 단계 "확인"을 집중적으로 연습

처리의 흐름 한눈에 보기

확인 → 판단 → 처리 → 재확인 — 닫히는 고리, 마지막 재확인을 빠뜨리지 말 것

STEP 1

확인

결측이 어디에 얼마나 있는지
파악



STEP 2

판단

컬럼·행별로 제거할지 대체할
지 결정



STEP 3

처리

실제로 제거 또는 대체 실행



STEP 4

재확인

결측이 정말 0이 됐는지 다시
검증 — 초보가 가장 자주 건너
뛰는 단계

일직선이 아닌 고리 — 결과가 어색하면 다시 확인으로 돌아오는 과정

실습 1. 눈으로 결측 찾기

설비 센서에서 진짜 결측과 위장 결측을 코드로 세기

목표

진짜 결측(NaN)과 위장 결측을 코드로 세어 확인

단계

- 설비 센서 데이터를 불러와 isnan으로 컬럼별 NaN 개수 세기
- 조건 필터링으로 압력 0, 진동 -999 같은 위장 결측 개수 세기
- 진짜 결측과 위장 결측을 나눠 비교

예상 결과

NaN 4개(온도2·압력1·진동1), 위장 압력0 2개·진동-999 2개

SECOM 반도체 공정 데이터

장난감 데이터 졸업 — 진짜 현장 데이터로

01 · 정체

**반도체 공정의
실제 센서 기록**

머리카락보다 가는 회로를 수백 단계로 새기는 공정의 감시 데이터

02 · 규모

**원본
1,567행 × 590개 센서**

센서 이름이 번호로만 된 건 공정이 기업 기밀이라 익명 공개

03 · 교육 샘플

**결측이 다양한
20개 센서 × 250행**

590개는 초보가 한눈에 보기 어려워 추린 교육용 데이터

read_csv로 불러오기

분석의 시작 — 파일을 표(DataFrame)로 불러오기. 빈 칸은 자동 NaN 변환

CODE

```
import pandas as pd

df = pd.read_csv("secom_교육샘플.csv")
df.head()
```

자동 변환 · 진짜 빈 칸은 자동으로 NaN으로 변환

한계 · 0이나 -999 같은 위장 결측은 그대로 진짜 숫자로 들어옴

초보 함정 · 파일명이 조금이라도 다르면 "파일 없음" 에러 — 이름과 위치 확인 필수

na_values로 위장 결측 인식

999·999 같은 위장 결측을 불러올 때부터 NaN으로 자동 변환

CODE

```
df = pd.read_csv(  
    "data.csv",  
    na_values=[ -999, 999]  
)
```

처음부터 정리 · 다 불러온 뒤 일일이 바꾸는 것보다 간편, 실수도 적음

컬럼별 지정 · 컬럼마다 다른 값을 결측으로 지정 가능

주의 · 0처럼 정상값일 수도 있는 걸 무턱대고 넣으면 멀쩡한 0까지 사라짐

info로 결측 한눈에 보기

데이터를 받으면 가장 먼저 실행하는 도구 — 데이터의 첫인상

01 · 채워진 값

컬럼별
non-null count 표시

`df.info()`

02 · 결측 추정

전체 - 채워진 값
= 결측 개수

250행인데 216개만 채워져 있으면 34개가 빈 칸

03 · 추가 단서

정수가 실수형이면
결측 의심 신호

모든 컬럼을 한 화면에서 비교 — 데이터 첫인상 잡기에 최고

describe의 count로 결측 추정

숫자 컬럼의 기초 통계 + count로 결측 추정 + 최솟값·최댓값으로 위장 결측 단서

01 · 기초 통계

평균·표준편차
최솟값·최댓값 표시

```
df.describe()
```

02 · count

결측이 아닌
값의 개수

250행인데 count가 141이면 109개가 결측

03 · 위장 결측 단서

min이 -999, max가 999
→ 의심 신호

비현실적인 최솟값·최댓값은 위장 결측 발견
의 단서

isna의 동작 원리

"is na — 결측이니?" — NaN/None을 정확히 잡아주는 전용 도구

CODE

```
df.isna()  
# 결측이면 True, 값이 있으면 False  
# 원래 데이터와 같은 크기의 참·거짓 표
```

원리 · 원본과 같은 크기의 참·거짓 표 — 결측이면 True, 값이면 False

등호의 함정 해결 · NaN/None을 모두 정확히 True로 잡음

짜깁 · 단독 출력은 수천 개라 못 셈 → sum()과 묶어 개수 카운트

isnull과 notna

이름이 비슷한 친구들 정리 — 초보는 **isna** 하나면 충분

Q 1. isnull은 isna와 다른가요?

A 완전히 같음. 판다스 역사적 이유로 같은 기능에 이름이 두 개일 뿐

Q 2. notna는 무엇인가요?

A isna의 반대 — 값이 있으면 참 (notnull도 동일)

Q 3. 무엇을 주로 쓰나요?

A 결측 셀 땐 **isna**, 값 있는 행만 골라낼 땐 **notna**

True는 1, sum으로 세기

`isna().sum()` — 결측 확인의 핵심 공식, 한 단어처럼 외우기

01 · 약속

컴퓨터는

True=1, False=0

아주 오래된 약속으로 참은 1, 거짓은 0

02 · 합산의 마법

참을 더하면

참의 개수

$T+F+T+T = 1+0+1+1 = 3$

03 · 공식

`df.isna().sum()`

isna가 위치를 표시 + sum이 개수를 합산 = 결측 개수

컬럼별 결측 개수 세기

한 줄로 데이터 전체의 결측 지도를 그리는 도구

CODE

```
df.isna().sum()  
# 센서01~08 : 0  
# 센서09 : 1 ... 센서20 : 109
```

결과 · 왼쪽 컬럼 이름 + 오른쪽 결측 개수의 세로 목록

SECOM 적용 · 센서01~08은 0개(깨끗), 센서09는 1개, 센서20은 109개

왜 컬럼별? · 결측 처리는 컬럼 단위로 판단 — 몇 개만 채울지, 절반이 비어 빼야 할지

전체 결측 개수와 비율

개수만 보면 안 됨 — 전체 대비 **비율**로 봐야 처리 방향이 보임

01 · 전체 개수

```
df.isna()  
.sum().sum()
```

sum을 한 번 더 → 우리 샘플 전체 결측 **475개**

02 · 비율 공식

(개수 / 250)
* 100

결측 개수를 전체 행 수로 나누고 100을 곱해 퍼센트

03 · 센서20 적용

109 / 250
= 43.6%

절반 가까이 빈 컬럼 — 채워봤자 절반이 추측, 제거 고민

결측 비율 정렬과 순위

`sort_values(ascending=False)` — 가장 심각한 컬럼이 맨 위로

센서	결측 개수	비율
센서20	109	43.6%
센서18	68	27.2%
센서17	60	24.0%
센서09	1	0.4%

위쪽은 빼는 걸 고민, 아래쪽은 채워 살리자 — 정렬 한 번이면 처리 우선순위가 보임

행별 결측 개수

시각을 90도 돌려 가로로 — "어느 측정 기록이 많이 비었나"

01 · 방향 전환

```
df.isna()  
.sum(axis=1)
```

방향 옵션을 가로(axis=1)로 지정

컬럼 시선 → 행 시선으로 90도 회전

행마다 결측이 몇 개인지 카운트

02 · SECOM 250행 결과

결측 없는 행 **76개**
결측 있는 행 **174개**

가장 많이 빠진 행은 **8개**나 비어 있음

거의 모든 센서가 빈 행은 측정 부실의 신호

통째로 빼는 게 나을 수 있음 — 다음 시간 주제

컬럼과 행 양쪽을 모두 봐야 전체 그림이 보임

결측 많은 행·컬럼 추출

문제 부분만 확대경으로 — 확인을 처리 판단으로 잇는 다리

01 · 컬럼 추출

결측 50개 초과
센서만 골라 보기

조건 필터링으로 센서17·18·19·20 추출

02 · 행 추출

결측 5개 이상
부실한 행만 보기

특정 시간대에 몰려 있다면 통신·설비 문제 추측

03 · 다리 역할

확인 결과를
처리 판단으로 넘김

추출한 결측 심한 컬럼 목록 = 다음 시간 "제거"
작업 지시서

결측 시각화 — 막대그래프

그림 한 장으로 보는 처리 우선순위 지도 — 막대가 높을수록 먼저 손볼 대상


가로축에 **센서 이름**, 세로축에 **결측 개수**

결측 많은 센서는 막대가 높이 솟고, 없는 센서는 바닥에 붙음

결측 많은 순으로 정렬해 그리면 더 깔끔

제목·축 설명을 달면 나중에 봐도 이해됨

→ 회의에서 남에게 설명할 때도 숫자보다 훨씬 직관적



결측 시각화 — 히트맵

결측이 데이터의 어느 위치에 몰려 있는지 — 가로 줄무늬는 동시 결측 신호

데이터 전체를 격자 색 지도로 펼치기

값 있는 칸은 짙은 남색, 결측은 노란색


강점은 패턴이 보이는 일 — 무작위인지, 특정 구간 집중인지

가로 줄무늬 = 그 시점에 여러 센서가 한꺼번에 멈춤

정전·설비 정지 같은 공통 사건의 신호 — 숫자만 보면 절대 못 잡음

→ 막대그래프(양) + 히트맵(위치) = 입체적 이해

250행 × 20센서 격자맵



■ 값 있음 ■ 측·우측(센서17~20)에 결측이 집중

확인 결과를 판단으로 연결

확인은 끝이 아니라 시작 — "그래서 어떻게 할 건데"로 가야 진짜 일

01 · 5% 미만

채워서 살리기
대체 (impute)

빠진 게 적으니 메워도 신뢰도가 크게 안 흔들림

02 · 40% 이상

제거 고민
drop

채워봤자 절반이 추측 — 오히려 결과를 왜곡

03 · 다만...

비율은 출발점
중요도·원인도 함께

분석에 꼭 필요한지 · 결측 원인 · 정답 컬럼인 지도 함께

비율 기준 처리 방향

결측 비율에 따라 처리 방향의 큰 기준을 잡기

결측 비율	처리 방향	해당 컬럼
5% 미만	대체로 살리기	센서09 ~ 13
5 ~ 30%	중요도 보고 결정	센서14 ~ 18
40% 이상	제거 고민	센서19 · 20

비율은 출발점. 분석 목적.결측 원인.정답 컬럼 여부도 함께 — 실무에선 원본 보관 + 처리 기록을 남기는 습관

실습 2. SECOM 첫 탐색

head·shape·info·describe로 결측 분위기 파악

목표

처음 받은 데이터의 구조와 결측 분위기 파악

단계

- read_csv로 불러와 head와 shape로 크기 확인
- info로 컬럼별 채워진 값 개수 훑기
- describe의 count로 결측 있는 컬럼 짐작

예상 결과

250행 22열, 뒤쪽 센서 컬럼일수록 채워진 수 감소

실습 3. 위장 결측 사냥

조건과 na_values로 위장 결측을 진짜 결측으로 전환

목표

위장 결측을 조건과 na_values로 진짜 결측으로 전환

단계

- 위장 결측이 있는 열을 조건 필터링으로 추출해 확인
- na_values로 위장값을 결측으로 인식해 다시 불러오기
- 변환 전후 결측 개수를 비교

예상 결과

변환 후 NaN 5개→8개 (진동 -999·온도 999 포함)

실습 4. 컬럼별 결측 개수와 비율

isna·sum으로 개수와 비율을 한 표로 정리

목표

컬럼별 결측 개수와 비율을 한 표로 정리

단계

- isna와 sum으로 컬럼별 결측 개수를 변수에 담기
- 전체 행 수로 나누고 백분율로 바꿔 비율 계산
- 결측이 있는 컬럼만 골라 개수와 비율을 나란히 정리

예상 결과

결측 12개 컬럼, 센서19·20이 각 109개(43.6%)로 최다

실습 5. 결측 순위와 행별 분석

정렬과 행 방향 카운트로 컬럼·행 두 방향 확인

목표

컬럼 순위와 행별 결측을 함께 봐 처리 근거 모으기

단계

- 결측 비율을 내림차순 정렬해 가장 심한 컬럼 확인
- 방향을 가로(행)로 바꿔 행마다 결측 개수 세기
- 결측이 많은 부실 행만 조건으로 골라내기

예상 결과

센서19·20 최상위, 결측 없는 행 76·있는 행 174

실습 6. 결측 시각화

막대그래프와 히트맵으로 양과 위치 보기

목표

막대그래프와 히트맵으로 결측의 양과 위치 보기

단계

- 컬럼별 결측 개수를 내림차순 정렬해 막대그래프로 그리기
- 결측 여부를 히트맵으로 그려 몰린 영역 확인
- 그림에서 결측이 집중된 뒤쪽 센서 확인

예상 결과

센서19·20 막대 최고, 뒤쪽 센서 영역에 결측 집중

실습 7. 결측 확인 요약표

개수·비율·처리방향 요약표를 만들어 저장

목표

개수·비율·처리방향을 담은 요약표를 만들어 저장

단계

- 컬럼별 개수와 비율을 하나의 표로 합치기
- 비율 기준으로 대체·검토·제거 처리 방향 열 추가
- 요약표를 파일로 저장해 다음 단계 지시서로 남기기

예상 결과

결측 12개 컬럼 요약표 + 처리방향, csv 저장