

05 통합 프로젝트 주제 후보

7개 주제 · 난이도 중상 이하 · 공개 데이터 기반 · 프로젝트 기간 내 완주 가능 범위

I. 난이도 기준

난이도	무엇이 다른가	이 과정에서의 위치
중하	데이터가 정돈되어 있고 라벨이 명확. 전처리 부담이 적어 해석에 시간을 쓸 수 있음	코딩에 아직 부담을 느끼는 팀의 안전한 선택
중	결측·불균형·대용량 등 실제 데이터의 문제가 하나 이상 존재. 시간 축 처리가 필수	표준 난이도 — 대부분의 팀에 권장
중상	신호 특징을 직접 만들어야 하거나, 다중 개체·다중 센서 구조를 다뤄야 함	01~04단원을 무리 없이 따라온 팀 대상

II. 전 주제 공통 요건

어떤 주제를 선택하든 아래는 동일하게 수행합니다. 주제별 차이는 "데이터의 성격"과 "무엇을 이상으로 정의하는가"에 있습니다.

	항목	요구 수준
1	시간 기준 데이터 분할	앞 구간 학습 / 뒤 구간 검증. 무작위 셔플 금지
2	기준 모델	Z-score 또는 이동 Z-score 기반 단순 기준 모델을 먼저 구축
3	머신러닝 모델	scikit-learn 모델 1~2종 (RandomForest, LogisticRegression, IsolationForest, One-Class SVM 등)
4	시계열 특성	이동평균 · 이동표준편차 · 변화율 · 시차 변수 중 3종 이상 생성
5	평가 지표	혼동행렬 + Precision · Recall · F1 (정확도 단독 금지)
6	오류 분석	오탐 1건 이상, 미탐 1건 이상을 시계열 그래프 위에 표시하고 원인 서술
7	도메인 해석	결과를 설비 상태와 보전 조치의 언어로 설명

산업용 펌프 정지 사고 사전 경보

예고 없이 멈추는 펌프를 몇 시간 전에 미리 알아챌 수 있는가.

현장 시나리오

유틸리티 펌프가 예고 없이 정지하면 후속 공정 전체가 멈춥니다. 정지 이전에도 센서값은 이미 흔들리고 있었을 가능성이 큼니다. 수십 개 센서가 동시에 기록된 데이터에서, 정지 시점보다 앞선 구간의 신호 변화를 찾아 "지금 점검이 필요하다"는 경보를 낼 수 있는지 확인합니다.

분석 문제

필수 과제	정지 발생 시점 기준 N시간 이전 구간을 "위험"으로 정의하고, 위험/정상을 구분하는 이진 분류 모델을 만든다. N은 팀이 정하고 근거를 밝힌다.
선택 과제	경보 선행시간(1h / 3h / 6h / 12h)을 바꿔가며 성능이 어떻게 변하는지 곡선으로 제시한다.
정의해야 할 것	"위험 구간"의 길이, 회복(RECOVERING) 구간을 학습에 포함할지 여부, 무의미한 센서의 제외 기준

데이터

출처	Kaggle — Pump Sensor Data (검색어: pump sensor data predictive maintenance)
규모	약 22만 행, 1분 간격, 2018년 약 5개월 분
변수	센서 약 50개(sensor_00 ~ sensor_51), timestamp, 설비 상태 라벨(machine_status)
라벨	NORMAL / BROKEN / RECOVERING — 정지(BROKEN) 시점이 명확히 표시되어 있음
왜 좋은가	결측·불용 센서·극단적 불균형이 모두 들어 있어 전처리 학습에 최적. 라벨이 있어 평가가 명확함

권장 분석 흐름

- 결측률이 높은 센서와 값이 거의 변하지 않는 센서를 기준을 세워 제외한다 (기준을 문서화할 것).
- 시간 인덱스를 정렬하고, 1 분 단위를 그대로 쓸지 10 분 평균으로 줄일지 결정한다.
- 정지 시점을 기준으로 위험 라벨을 부여하는 함수를 만든다 — 눈으로 찍지 말고 규칙으로 부여한다.
- 이동평균·이동표준편차·변화율 특성을 만들고, 정지 직전 구간에서 눈에 띄게 달라지는 센서를 찾는다.
- Z-score 기준 모델 → RandomForest 또는 LogisticRegression 순으로 비교한다.
- 경보가 실제로 정지 몇 시간 전에 울렸는지 시계열 그래프 위에 표시한다.

이 주제의 난점

- 정지 사례 수가 적어 검증 구간에 정지가 한 번도 없을 수 있다. 분할 지점을 신중히 정하고 근거를 남길 것.
- BROKEN 시점 자체를 학습에 넣으면 "이미 고장난 것을 맞히는" 모델이 된다. 위험 구간은 정지 이전으로만 잡는다.
- 센서가 많아 특성이 폭증하기 쉽다. 상위 10~15 개 센서로 좁히고 선택 근거를 밝힐 것.

이런 팀에 권장

이 과정의 표준 주제입니다. 특별한 이유가 없다면 이 주제부터 검토하십시오. 실제 데이터의 지저분함을 경험하면서도 라벨이 있어 평가가 명확합니다.

주제 B 난이도 중하

회전설비 고장 유형 조기 판별

운전 조건만 보고 고장 여부와 고장의 종류까지 구분할 수 있는가.

현장 시나리오

동일한 설비라도 과부하로 멈추는 경우, 열이 빠지지 않아 멈추는 경우, 공구·부품 마모로 멈추는 경우는 대응 방법이 전혀 다릅니다. 온도·회전속도·토크·마모량 같은 운전 조건에서 고장 여부뿐 아니라 고장의 유형까지 구분할 수 있다면, 보전 담당자는 무엇을 점검해야 하는지 바로 알 수 있습니다.

분석 문제

필수 과제	고장 여부 이진 분류 + 고장 유형(공구 마모 / 방열 실패 / 과부하 / 과변형 등) 다중 분류
선택 과제	각 고장 유형에서 어떤 변수가 결정적이었는지 변수 중요도로 분석하고 물리적 해석을 붙인다.
정의해야 할 것	마모량 누적 축을 어떻게 시간 축처럼 다룰지, 유형별 표본이 너무 적을 때의 처리 방침

데이터

출처	UCI Machine Learning Repository — AI4I 2020 Predictive Maintenance Dataset
규모	10,000행 · 14열 — 가볍고 결측이 없음
변수	제품 등급(L/M/H), 공기 온도, 공정 온도, 회전속도(rpm), 토크(Nm), 공구 마모(min)
라벨	고장 여부 + 5가지 고장 모드(공구 마모, 방열 실패, 전력, 과변형, 무작위)
왜 좋은가	전처리 부담이 적어 팀이 "모델 실행"이 아니라 "결과 해석"에 시간을 쓸 수 있음

권장 분석 흐름

- 변수 간 관계를 먼저 본다 — 회전속도와 토크의 곱(전력), 공기 온도와 공정 온도의 차이 같은 파생 변수를 만든다.
- 공구 마모량을 시간 축으로 삼아 이동 통계와 변화율 특성을 생성한다 (이 단계를 생략하면 시계열 요건 미충족).
- Z-score 기준 모델 → 분류 모델 순으로 비교한다.
- 고장 유형별 혼동행렬을 만들어 어떤 유형끼리 헷갈리는지 확인한다.
- 변수 중요도를 물리적으로 해석한다 — 왜 그 변수가 그 고장 모드를 설명하는가.

이 주제의 난점

- 데이터가 깨끗한 만큼 "전처리를 열심히 했다"라는 점수를 받기 어렵다. 도메인 해석의 깊이로 승부해야 한다.

- 고장 표본이 전체의 약 3%대로 불균형하다. 정확도로 판단하면 반드시 틀린다.
- 시간 측이 명시되어 있지 않으므로, 마모 누적을 시간처럼 다루는 근거를 반드시 문서에 남겨야 한다.

이런 팀에 권장

코딩에 아직 부담이 있는 팀, 또는 팀원 간 실력 차가 큰 팀에 권장합니다. 전처리에서 진을 빠지 않고 분석 논리를 완성할 수 있습니다.

열처리 공정 이상 구간 탐지

대용량 국내 제조 데이터에서 설비가 평소와 다르게 움직인 구간을 찾아낼 수 있는가.

현장 시나리오

열처리 공정은 온도·시간 조건이 조금만 어긋나도 품질에 직결됩니다. 설비가 평소 운전 패턴에서 벗어난 구간을 자동으로 선별할 수 있다면, 담당자는 전체 이력을 다 보지 않고도 확인이 필요한 구간부터 볼 수 있습니다. 국내 제조 현장에서 실제로 수집된 데이터를 다룬다는 점에서 결과를 현장 언어로 설명하기에 가장 유리한 주제입니다.

분석 문제

필수 과제	공정 변수 기준으로 정상 운전 구간과 이상 구간을 구분하고, 이상 후보 구간을 시간축 위에 표시한다.
선택 과제	이상 구간과 품질 결과의 관계를 확인해, 어떤 이상 패턴이 품질 저하로 이어지는지 정리한다.
정의해야 할 것	전체 데이터 중 어느 기간·어느 설비를 표본으로 삼을지, 이상의 판정 단위(개별 시점 / 배치 / 구간)

데이터

출처	KAMP(인공지능 중소벤처 제조 플랫폼, kamp-ai.kr) 제조AI 데이터셋 — 열처리 품질보증 데이터셋
규모	수천만 건 규모의 대용량 (전체를 그대로 쓰지 않고 기간·설비 단위로 표본을 뽑아 사용)
변수	공정 조건 변수(온도·시간 등)와 품질 판정 정보 — 상세 항목은 KAMP 제공 가이드북 참조
이용 방법	KAMP 회원 가입 후 무료 내려받기. 데이터셋별 가이드북이 함께 제공됨
대안	KAMP의 CNC · 프레스 · 사출성형기 등 다른 설비 데이터셋으로 대체 가능 (담당 강사 승인 필요)

권장 분석 흐름

- 전체 데이터를 열지 말고, 먼저 일부만 읽어 구조와 용량을 파악한다 (읽기 전략 자체가 학습 포인트).
- 분석 대상 기간·설비를 정하고, 표본 추출 기준을 문서화한다.
- 정상 운전의 기준 프로파일을 정의한다 — 시간대별 평균과 허용 범위.
- 이동 Z-score 로 기준을 벗어난 구간을 찾고, IsolationForest 결과와 비교한다.
- 검출된 구간을 실제 시계열 위에 색으로 표시하고, 각 구간이 왜 이상인지 서술한다.

이 주제의 난점

- 데이터 용량이 커서 노트북 메모리가 부족할 수 있다. 청크 단위 읽기와 다운샘플링 방침을 2 단계 안에 반드시 확정할 것.
- 가이드북의 컬럼 설명을 읽지 않고 시작하면 변수 의미를 오해하기 쉽다.
- 라벨(품질 판정)이 있는 경우에도 그것을 이상 탐지의 정답으로 그대로 쓰면 문제 정의가 흐려진다. 무엇을 정답으로 볼지 먼저 정할 것.

이런 팀에 권장

결과를 국내 제조 현장 맥락에서 설명하고 싶은 팀, 대용량 데이터 처리를 경험해 보고 싶은 팀에 권장합니다.

주제 D 난이도 중

라벨 없는 설비 데이터에서 점검 후보 선별

"무엇이 고장인지" 알려주는 정답이 없을 때, 이상해 보이는 구간을 어떻게 찾을 것인가.

현장 시나리오

실제 현장에서는 고장 이력이 정리되어 있지 않은 설비가 훨씬 많습니다. 정답 라벨이 없는 상태에서 "평소와 다른 상태"를 찾아 점검 후보로 올리는 것이 예지보전의 현실적인 출발점입니다. 이 주제는 라벨을 쓰지 않고 모델을 만든 뒤, 마지막에만 라벨로 검증해 비지도 이상 탐지가 실제로 쓸 만한지를 확인합니다.

분석 문제

필수 과제	라벨을 사용하지 않고 이상 후보 구간을 선별한 뒤, 마지막 단계에서만 라벨과 대조해 적중 여부를 평가한다.
선택 과제	탐지 민감도를 조절해 "하루에 몇 건까지 점검 가능한가"라는 운영 제약 아래 최적 설정을 제안한다.
정의해야 할 것	이상 점수를 어느 값 이상일 때 후보로 올릴지, 연속된 이상 시점을 하나의 사건으로 묶는 규칙

데이터

출처	아래 중 택일 — ① 주제 A의 펌프 데이터를 라벨 미사용 조건으로 사용 ② KAMP 설비 계열 데이터셋 ③ UCI SECOM 공정 데이터
권장	①이 가장 안전합니다. 같은 데이터라도 문제 정의가 달라 A팀과 결과물이 겹치지 않습니다
모델	IsolationForest, One-Class SVM, 이동 Z-score, 재구성 오차 기반 방법
평가	라벨은 마지막 검증에만 사용 — 탐지 구간이 실제 고장 이전 구간과 겹치는 비율로 평가

권장 분석 흐름

- 정상 구간만으로 "평소의 모습"을 학습시킨다.
- 이상 점수를 시간축에 그려 점수가 치솟는 구간을 찾는다.
- 연속된 이상 시점을 하나의 사건으로 묶는 규칙(예: 30 분 내 연속 발생 시 1 건)을 정한다.
- 하루 평균 몇 건의 후보가 나오는지 계산한다 — 현장에서 감당 가능한 수준인지가 핵심 평가 지점.
- 마지막에만 라벨을 열어 후보 구간이 실제 고장 전 구간과 겹치는지 확인한다.

이 주제의 난점

- 평가 방식을 스스로 설계해야 해서 초반에 헤매기 쉽다. 게이트 1(착수 보고)에서 평가 방식까지 정해 놓을 것.

- 민감도를 높이면 후보가 폭증한다. "많이 찾았다"가 아니라 "볼 만한 양으로 찾았다"가 목표임을 잊지 말 것.
- 라벨을 중간에 들여다보면 이 주제의 의미가 사라진다. 라벨 파일을 별도 폴더에 분리해 두고 진행할 것.

이런 팀에 권장

"정답이 없는 상황"이라는 현실적인 조건에 흥미를 느끼는 팀에 권장합니다. 다만 평가 설계를 스스로 해야 하므로 팀장의 정리 능력이 중요합니다.

대형 회전기 베어링 열화 추적과 교체 시점 판단

진동 신호에서 열화가 시작된 시점을 찾고, 교체 판단의 근거를 만들 수 있는가.

현장 시나리오

회전기의 베어링은 어느 날 갑자기 파손되는 것이 아니라 서서히 열화합니다. 진동 신호는 초당 수천 회 기록되지만 그 자체로는 해석할 수 없습니다. 여기서 필요한 것은 신호를 하나의 대표값으로 요약해 시간에 따라 늘어놓는 일입니다. 요약값이 언제부터 증가하기 시작했는지를 찾는 것이 이 주제의 핵심입니다.

분석 문제

필수 과제	진동 신호에서 시간 영역 특징(RMS, 첨도, 최댓값, 파고율)을 산출해 열화 곡선을 만들고, 열화 시작 시점을 탐지한다.
선택 과제	주파수 영역(FFT) 특징을 추가해 어떤 결함 주파수가 나타나는지 확인한다.
정의해야 할 것	"열화가 시작되었다"를 판정하는 규칙, 교체 권고 시점을 제시하는 기준

데이터

출처	NASA PCoE — IMS Bearing Dataset (run-to-failure 진동 데이터), 또는 CWRU Bearing Data Center
규모	고속 샘플링 진동 신호가 일정 간격으로 반복 기록된 구조. 원본 용량이 큼
변수	가속도계 진동값 (원신호) — 특징 산출은 팀이 직접 수행
라벨	완전 파손 시점이 알려져 있어 열화 곡선의 타당성을 사후 검증할 수 있음
난이도 조정	전처리 부담이 크므로, 신호를 특징값으로 변환하는 코드 뼈대는 담당 강사가 템플릿으로 제공합니다

권장 분석 흐름

- 원신호 파일 하나를 열어 구조를 파악한다 — 샘플링 주기, 채널 수, 파일당 기록 길이.
- 파일 단위로 RMS·첨도·최댓값·파고율을 계산해 시간 순으로 이어 붙인다 (여기서 표 형태 데이터가 만들어진다).
- 이후는 일반 시계열 분석과 동일하다 — 추세를 보고 변곡점을 찾는다.
- 초기 정상 구간의 통계로 기준선을 잡고, 이동 Z-score 로 이탈 시점을 탐지한다.
- 탐지 시점이 실제 파손보다 얼마나 앞섰는지를 정량화해 "얼마나 미리 알 수 있었는가"로 결론을 낸다.

이 주제의 난점

- 원신호 처리에서 시간을 다 쓰기 쉽다. 게이트 2(데이터·전처리)까지 특징 데이터 생성이 끝나지 않으면 주제 변경을 검토할 것.
- 파일 수가 많아 반복 처리 코드가 필요하다 — 01 단원의 파일 입출력·함수 작성이 확실해야 한다.
- 주파수 분석은 선택 과제다. 필수 과제를 끝내기 전에 손대지 말 것.

이런 팀에 권장

01단원 파일 처리와 함수 작성이 편안한 팀에 권장합니다. 진동·신호에 관심 있는 팀원이 있다면 좋은 선택이지만, 팀 전체가 코딩에 부담을 느낀다면 주제 A나 B를 권합니다.

터보팬 엔진 고장 임박 예측

여러 대의 설비가 각각 다른 속도로 열화할 때, 지금 위험한 개체를 골라낼 수 있는가.

현장 시나리오

동일 기종 설비 여러 대를 함께 운용하면, 같은 시점이라도 개체마다 남은 수명이 다릅니다. 이 데이터는 100대의 엔진이 각각 정상 상태에서 고장까지 운전된 전체 이력을 담고 있어, "설비별로 열화 속도가 다르다"는 현실을 그대로 다룰 수 있습니다. 잔여 사이클이 일정 수준 이하인 상태를 위험으로 정의해 분류하는 것이 이 주제의 필수 과제입니다.

분석 문제

필수 과제	잔여 사이클이 임계값(예: 30) 이하인 구간을 "위험"으로 정의하고 이진 분류 모델을 만든다.
선택 과제	RUL(잔여 유효 수명) 회귀를 시도하고, 분류 방식과 어느 쪽이 현장에서 더 쓸모 있는지 비교한다.
정의해야 할 것	위험 임계 사이클 수와 그 근거, 개체별로 분할할지 시점별로 분할할지

데이터

출처	NASA PCoE — C-MAPSS Turbofan Engine Degradation Simulation Dataset (FD001 하위 세트 권장)
규모	학습 100대 · 시험 100대, 개체별 수십~수백 사이클, 총 2만 행대
변수	운전 조건 3개 + 센서 21개 (사이클 단위 기록)
라벨	학습 데이터는 고장까지 운전된 전체 이력 — 잔여 사이클을 직접 계산해 라벨을 만든다
왜 중상인가	개체(엔진) 단위로 데이터를 나눠야 하고, 변화가 없는 센서를 골라내야 함. 단 결측이 없어 전처리 부담은 낮음

권장 분석 흐름

- 개체별로 마지막 사이클을 찾아 각 시점의 잔여 사이클을 계산한다 (이 계산이 이 주제의 첫 관문).
- 값이 거의 변하지 않는 센서를 제외한다 — 21 개 중 상당수가 그렇다.
- 개체 단위로 학습/검증을 나눈다. 같은 엔진의 데이터가 양쪽에 섞이면 성능이 부풀려진다.
- 개체별 이동평균·변화율 특성을 만든다 (개체 경계를 넘지 않도록 그룹 연산으로 처리할 것).
- Z-score 기준 모델 → 분류 모델 순으로 비교하고, 임계 사이클 수를 바꿔가며 성능 변화를 본다.

이 주제의 난점

- 공개된 예제 코드가 매우 많은 데이터셋이다. 그대로 가져다 쓰면 배우는 것이 없고 평가에서도 불리하다. 참고한 자료는 README 에 반드시 출처를 남길 것.
- 개체 경계를 무시하고 이동평균을 계산하는 실수가 잦다 — 반드시 그룹 단위 연산으로 처리한다.
- 실제 설비가 아닌 시뮬레이션 데이터이므로, 도메인 해석에서 "실제 현장과 다른 점"을 함께 언급해야 한다.

이런 팀에 권장

데이터가 정돈되어 있어 분석 논리에 집중하고 싶지만 난이도는 낮추고 싶지 않은 팀에 권장합니다. 다만 참고 자료가 많은 만큼 차별화된 문제 정의가 필요합니다.

주제 G 난이도 별도 승인

팀 자율 주제

팀이 직접 문제를 정의하고 데이터를 찾아오는 경우.

현장 시나리오

팀원 중 관련 업무 경험이 있거나 특정 설비에 관심이 있는 경우, 자체 주제를 제안할 수 있습니다. 다만 정해진 프로젝트 기간 안에 완주해야 하므로 데이터 확보가 늦어지는 주제는 허용하지 않습니다.

분석 문제

승인 조건	① 시간 축이 있는 데이터 ② 정상/이상을 규칙으로 정의 가능 ③ 1단계 종료 전 데이터 확보 가능 ④ 설비·공정·장비 도메인
제출 시점	1단계 첫날 종료 전까지 제안서(A4 1매) 제출 — 문제, 데이터 출처와 규모, 예상 분석 흐름 포함
승인 주체	담당 강사. 1단계 내 승인 여부 통보

데이터

탐색 경로	KAMP(kamp-ai.kr) · 공공데이터포털(data.go.kr) · AI-Hub · UCI ML Repository · Kaggle · NASA PCoE
불가 사례	데이터 수집·크롤링이 필요한 주제, 시점 정보가 없는 표 데이터, 설비와 무관한 도메인

권장 분석 흐름

- 공통 요건(II장)은 자율 주제에도 동일하게 적용됩니다.

이 주제의 난점

- 데이터 확보에 실패하면 게이트 1 시점에 지정 주제로 강제 전환됩니다. 이 경우 착수 단계를 다시 밟게 됩니다.

이런 팀에 권장

관련 업무 경험이 있는 팀원이 있고, 이미 후보 데이터를 확인해 둔 팀에만 권장합니다.

Ⅲ. 주제 선택 가이드

팀 상황	권장 주제	이유
팀 전체가 코딩에 부담을 느낀다	B	전처리 부담이 가장 적어 해석과 문서화에 시간을 쓸 수 있음
평범하게 잘 해내고 싶다	A	실제 데이터의 문제를 겪되 라벨이 있어 완주 가능성이 높음
국내 제조 맥락으로 설명하고 싶다	C	KAMP 국내 데이터, 한국어 가이드북 제공
현실적인 조건을 다뤄보고 싶다	D	라벨 없는 상황의 이상 탐지 — 문제 설계 역량이 길러짐
파일 처리·함수 작성이 편하다	E	신호에서 특징을 직접 만드는 경험을 할 수 있음
정돈된 데이터로 논리에 집중하고 싶다	F	전처리 부담은 낮고 데이터 구조 설계는 까다로움
업무 경험 기반 주제가 있다	G	단, 데이터 확보가 선행되어야 함

Ⅳ. 데이터 확보 경로

출처	주소	특징
KAMP 인공지능 제조 플랫폼	kamp-ai.kr	국내 제조 설비·공정 데이터셋과 한국어 가이드북. 회원 가입 후 무료
공공데이터포털	data.go.kr	KAMP 데이터셋 목록 등 공공 데이터 통합 검색
AI-Hub	aihub.or.kr	국내 산업 AI 학습용 데이터. 이용 신청 절차가 있어 시간 여유 필요
UCI ML Repository	archive.ics.uci.edu	정돈된 학습용 데이터셋. AI4I 2020 등
Kaggle	kaggle.com/datasets	실무형 데이터가 많음. 펌프 센서 데이터 등
NASA PCoE	NASA 예지진단센터 데이터 저장소	C-MAPSS, IMS Bearing 등 예지보전 표준 데이터

데이터 확보 시 주의

- 내려받기에 가입·승인 절차가 필요한 곳이 있습니다. 프로젝트 첫날 바로 신청하십시오.
- 데이터 원본은 제출 폴더에 넣지 않습니다. README에 출처와 내려받는 방법만 기재합니다.
- 사용 조건(라이선스)을 확인하고 보고서에 출처를 명시하십시오.
- 위 목록의 데이터셋 명칭과 제공 여부는 시점에 따라 달라질 수 있으므로, 회차 시작 시 실제 접속해 확인한 뒤 확정하십시오.