

05 통합 프로젝트 진행 가이드

문제 정의부터 보전 관점 해석까지, 하나의 분석 흐름으로 연결하기

1. 프로젝트 개요

1. 목적

01~04단원에서 개별 실습으로 익힌 기술을 하나의 문제 해결 과정으로 연결합니다. 설비 데이터에서 분석 문제를 스스로 정의하고, 전처리 → 시계열 분석 → 모델링 → 평가 → 보전 관점 해석까지 수행한 뒤, 다른 사람이 다시 실행해도 같은 결과가 나오는 재현 가능한 결과물을 완성하는 것이 목표입니다.

2. 프로젝트가 끝났을 때의 상태

- 주어진 설비 데이터에서 "무엇을 정상으로 보고 무엇을 이상·고장 위험으로 볼지"를 근거와 함께 정의할 수 있다.
- 시간 순서를 유지한 전처리와 시계열 분석으로 상태 변화 구간을 찾아 설명할 수 있다.
- 기준 모델과 머신러닝 모델을 같은 조건에서 비교하고, 성능지표와 오탐·미탐을 해석할 수 있다.
- 모델이 판단하지 못하는 한계와 현장 적용 시 필요한 보완 사항을 제시할 수 있다.

2. 운영 기준

1. 기간 운영

이 가이드는 특정 일수를 전제하지 않고, 전체 기간을 6단계로 나누어 각 단계에 배분할 비중을 기준으로 삼습니다.

항목	기준
운영 단위	하루 8시간 기준, 6단계로 구성
최소 요건	어느 회차든 6단계를 모두 거칩니다. 기간이 짧아지면 단계를 빼는 것이 아니라 각 단계를 압축합니다.
일정 확정	담당 강사가 회차 시작 시 단계별 시작·종료일과 게이트 일자를 공지
버퍼	전체 기간의 약 5%를 예비일로 남겨 두기를 권장 (지연 흡수용)

2. 팀 구성과 역할

한 팀은 4~5명으로 구성합니다. 아래 역할은 "그 사람만 한다"는 뜻이 아니라 "그 부분의 진행과 품질을 책임진다"는 뜻입니다. 코드 작성은 전원이 함께합니다.

역할	책임 범위	주요 산출물
팀장 (PM)	일정 관리, 게이트 준비, 강사 소통, 의사결정 정리	진행 기록, 회의 메모, 최종 발표 총괄
데이터 담당	데이터 확보, 품질 점검, 전처리 파이프라인 관리	전처리 코드, 데이터 명세 표
시계열·특성 담당	추세·주기·변동성 분석, 파생 특성 생성	시계열 분석 노트북, 특성 정의서
모델링 담당	기준 모델 및 머신러닝 모델 학습·비교	모델 코드, 성능 비교 표
해석·문서 담당	오탐/미탐 사례 정리, 보전 관점 해석, 문서 편집	결과보고서, 발표자료, README

4인 팀은 "시계열·특성"과 "모델링"을 한 명이 겸하거나, "해석·문서"를 팀장이 겸합니다.

3. 팀 내 점검 활동 (참고)

아래는 규정이 아니라 제안입니다. 팀 상황에 맞게 골라 쓰거나 변형해서 운영하십시오.

활동	이렇게 해보십시오
하루 시작 공유 (15분)	어제 한 것 / 오늘 할 것 / 막힌 것 한 가지를 돌아가며 말합니다. 길어지면 따로 잡습니다.
30분 규칙	같은 오류에 혼자 30분 이상 붙잡혀 있지 않기로 팀 내 합의합니다. 팀 공유 → 강사 순으로 물어봅니다.
작업 규칙 정하기	폴더 구조와 파일 이름 규칙을 첫날 정해 두면 나중에 코드를 합칠 때 시간을 크게 아킵니다.
변경 기록 한 줄	무엇을 왜 바꿨는지 한 줄씩 남깁니다. 보고서를 쓸 때 이 기록이 그대로 근거가 됩니다.
단계 종료 회고 (10분)	무엇이 잘 됐고 무엇이 걸렸는지, 다음 단계에서 역할을 조정할지 확인합니다.
중간 리허설	최종 발표 전에 팀끼리 한 번 설명해 봅니다. 말이 막히는 지점이 곧 논리가 빈 지점입니다.

4. 트랙 구분

구분	기초 트랙 (전 팀 공통)	응용 트랙 (선택)
모델	Z-score 기준 모델 + scikit-learn 모델 1~2종	양상블 비교, 하이퍼파라미터 탐색, 딥러닝 (LSTM 등)
문제 유형	이상 탐지 또는 고장 임박 이진 분류 중 1개	두 가지 모두 수행, 또는 RUL(잔여수명) 회귀 시도
특성	이동평균·이동표준편차·변화율 등 기본 시계열 특성	주파수 영역(FFT) 특성, 다중 센서 상관 특성
평가	혼동행렬, Precision·Recall·F1, 임계값 1회 조정	PR 곡선, 경보 선행시간(lead time)별 성능 비교

3. 진행 절차 8 단계

	단계	주요 작업	완료 기준 (이것이 되면 통과)
1	문제 정의	대상 설비 선정, 분석 목적 서술, 정상/이상 기준과 성공 기준 설정	"어떤 설비의 무엇을, 왜, 어느 수준까지 맞히면 성공인가"를 한 문단으로 설명할 수 있다
2	데이터 이해	변수 목록, 단위, 수집 주기, 시간 범위, 결측·이상치 현황 정리	변수 명세 표가 완성되고, 분석 불가능한 변수와 그 이유가 명시되어 있다
3	전처리 · 기초 분석	시간 인덱스 정리, 결측·중복 처리, 기초 통계와 시각화	전처리 코드를 다시 실행하면 동일한 데이터가 재생성된다
4	시계열 패턴 분석	추세·주기·변동성 분석, 상태 변화 구간 식별	"이 구간이 변화 구간이다"라고 지목하고 근거 그래프를 제시할 수 있다
5	기준 모델 · 머신러닝	Z-score 등 단순 기준 적용 후 이상 탐지/분류 모델 학습	두 모델을 같은 데이터 분할 조건에서 비교한 표가 있다
6	평가 · 오류 분석	성능지표 산출, 오탐·미탐 사례 추출과 원인 분석	오탐 1건 이상, 미탐 1건 이상을 그래프로 짚고 원인을 설명할 수 있다
7	도메인 해석 · 개선	결과의 현장 의미, 활용 가능성, 한계와 개선 방향 정리	"이 결과를 보전 담당자가 어떻게 쓰는가"를 설명할 수 있다
8	문서화 · 발표	코드 정리, README, 결과보고서, 발표자료 완성	제3자가 README만 보고 코드를 실행해 결과를 재현할 수 있다

4. 분석 공통 필수 요건

1. 데이터 처리 규칙

- 시간 순서를 유지한 상태로 학습/검증을 분할합니다. 무작위 셔플(train_test_split 의 기본 동작) 사용을 금지합니다.
- 스케일러·인코더는 학습 구간에서만 fit 하고, 검증 구간에는 transform 만 적용합니다.
- 결측 보간 시 미래 값을 끌어와 채우지 않습니다. 앞 시점 값(ffill) 또는 구간 평균 등 과거 정보만 사용합니다.
- 목표값과 사실상 같은 정보를 담은 변수(예: 정비 이력 코드, 고장 알람 플래그)를 입력 특성으로 쓰지 않습니다.

2. 모델링 규칙

- Z-score 등 단순 기준 모델을 반드시 먼저 만들고 성능을 기록합니다. 이것이 비교의 출발점입니다.
- 머신러닝 모델은 1~2 종(최대 3 종)만 사용합니다. 권장: RandomForest, LogisticRegression, IsolationForest, One-Class SVM.
- 모델을 바꿀 때마다 데이터 분할·특성·평가 지표를 동일하게 유지합니다. 조건이 다르면 비교가 아닙니다.
- 학습에 사용한 난수 시드(random_state)를 고정하고 기록합니다.

3. 평가 규칙

- 정확도(accuracy) 단독 보고를 금지합니다. 고장 데이터는 대부분 불균형이라 정확도는 쉽게 높아집니다.
- 혼동행렬과 Precision · Recall · F1 을 함께 제시합니다.
- 오탐 1 건 이상, 미탐 1 건 이상을 실제 시계열 그래프 위에 표시하고 왜 틀렸는지 서술합니다.
- 임계값을 조정한 경우, 왜 그 값을 선택했는지 보전 관점(점검 비용 vs 고장 누락 위험)에서 설명합니다.

4. 자주 발생하는 실수

흔한 실수	왜 문제인가	이렇게 하십시오
데이터를 무작위로 섞어 분할	미래 정보가 학습에 섞여 성능이 실제보다 훨씬 높게 나옵니다	시간 기준으로 앞 구간=학습, 뒤 구간=검증
전체 데이터로 스케일링 후 분할	검증 구간의 통계가 학습에 새어 들어갑니다	분할 먼저, 스케일링은 그 다음

흔한 실수	왜 문제인가	이렇게 하십시오
정확도 99%로 결론	이상이 1%인 데이터는 전부 정상이라 찍어도 99%입니다	Recall과 혼동행렬로 판단
이상 구간을 눈으로 정하고 라벨로 사용	정답을 보고 문제를 만든 셈이 됩니다	라벨 정의 규칙을 먼저 문서화한 뒤 일괄 적용
모델 5~6종 나열	어느 것도 깊이 해석하지 못합니다	2종 비교 + 오류 사례 깊이 분석
그래프에 축 이름·단위 없음	해석의 근거로 쓸 수 없습니다	모든 그림에 축 이름, 단위, 제목 표기

5. 제출물 규격

1. 제출물 목록

	제출물	내용	형식
1	문제정의서	대상 설비, 분석 목적, 정상/이상 정의, 성공 기준	PDF 또는 DOCX (1~2매)
2	분석 코드	전처리 · 시계열 분석 · 모델링 · 평가 코드	.ipynb 또는 .py
3	시계열 분석 결과	추세·주기·변동성 분석과 상태 변화 구간 근거	보고서 내 포함 + 그림 파일
4	모델 평가서	기준 모델 vs 머신러닝 모델 비교, 지표 표	보고서 내 포함
5	오탐·미탐 사례 분석	사례 2건 이상, 시각화와 원인 서술	보고서 내 포함
6	결과보고서	전 과정 종합, 도메인 해석, 한계와 개선 방향	PDF (8~15매)
7	발표자료	최종 발표용 슬라이드	PPTX 또는 PDF (12~18 장)
8	README	실행 방법, 폴더 구조, 데이터 출처와 내려받는 법	README.md

2. 제출 폴더 구조

[팀번호]_[팀명]_[프로젝트명]/

README.md ← 실행 방법 · 데이터 출처 · 팀원과 역할

data/ ← 원본 데이터는 넣지 않고, 내려받는 방법만 기재

notebooks/ 01_eda.ipynb 02_timeseries.ipynb 03_model.ipynb 04_eval.ipynb

src/ preprocess.py features.py model.py

figures/ 그림 파일 (파일명에 번호와 내용 포함)

reports/ 문제정의서.pdf 결과보고서.pdf 발표자료.pdf

3. 결과보고서 목차 (권장)

장	제목	답을 내용
1	문제 정의	대상 설비, 분석 목적, 정상/이상 정의, 성공 기준
2	데이터 개요	출처, 기간, 변수 명세, 품질 이슈
3	전처리	처리 절차와 판단 근거, 처리 전후 비교

장	제목	답을 내용
4	시계열 분석	추세·주기·변동성, 상태 변화 구간과 근거
5	모델링	기준 모델, 머신러닝 모델, 데이터 분할 방식, 특성 목록
6	평가와 오류 분석	성능 비교 표, 혼동행렬, 오탐·미탐 사례
7	보전 관점 해석	결과의 현장 의미, 활용 시나리오, 임곗값 선택 근거
8	한계와 개선 방향	이 분석이 판단하지 못하는 것, 다음에 필요한 데이터
9	역할과 회고	팀원별 담당, 배운 점

4. 최종 발표 구성

순서	내용
① 문제	어떤 설비의 어떤 문제인가, 왜 이 문제가 중요한가, 무엇을 이상으로 정의했는가
② 데이터·전처리	데이터의 성격과 품질 문제, 어떻게 정리했는가
③ 시계열 분석	무엇이 보였는가 — 그래프 중심
④ 모델과 결과	기준 모델 대비 무엇이 나아졌는가, 성능 표
⑤ 오류와 해석	어떤 경우를 틀렸는가, 현장에서 이 결과를 어떻게 쓰는가
⑥ 한계와 다음	무엇을 못 했는가, 무엇이 더 필요한가

※ 코드 화면을 그대로 띄우는 발표는 지양합니다. 그래프와 표로 판단 근거를 보여주십시오.