

AI 데이터 분석 핵심 라이브러리

Pandas 기초: DataFrame 구조와 통계 미리보기

탐색적 데이터 분석(EDA)을 위한 빠른 점검 및 기초 통계 분석 가이드

AI 데이터 분석 교재 | 대상: 데이터 분석 학습자

1. 데이터 탐색(Exploration)의 목적

PART 01. 데이터 미리보기

왜 먼저 들여다보아야 하는가?

- 데이터를 받자마자 바로 분석이나 모델링으로 가지 않음
- 데이터의 크기, 형태, 이상치, 결측치를 먼저 눈으로 확인
- 잘못된 데이터 타입이나 결측치를 방치하면 분석 전체가 왜곡됨

탐색 시 확인해야 할 3대 핵심 요점

1. **크기:** 몇 행, 몇 열짜리 데이터인가?
2. **내용:** 열 이름과 실제 수집된 값은 어떤 모양인가?
3. **이상 신호:** 빈 칸(NaN)이나 말도 안 되게 튼 숫자가 있는가?

2. 데이터 미리보기: head()와 tail()

PART 01. 데이터 미리보기

head(n): 위에서 n줄 확인

- 기본값: 위에서 5줄 출력
- 열 이름과 상위 측정값 패턴, 결측 여부 1차 점검

```
df.head()      # 위에서 5줄  
df.head(10)    # 위에서 10줄
```

tail(n): 아래에서 n줄 확인

- 기본값: 아래에서 5줄 출력
- 파일 끝부분 찢림, 오타, 최신 시점 수집 데이터 상태 점검

```
df.tail()      # 아래에서 5줄  
df.tail(3)     # 아래에서 3줄
```

NaN (Not a Number) 결측치의 발견

head() 및 tail()을 실행했을 때 NaN 표시가 등장하면, 해당 시점에 센서 고장이나 통신 끊김으로 측정값이 빠졌음을 의미합니다. (숫자 0과는 완전히 다름!)

3. DataFrame의 뼈대 속성 4종 (shape, columns, index, dtypes)

PART 01. 구조 파악

★ 주의: 4가지 속성은 이미 저장된 성질이므로 괄호 ()를 붙이지 않습니다!

속성명	설명 및 반환 형태	예시 및 분석 의미
<code>df.shape</code>	행과 열의 크기 (튜플 (행, 열))	<code>(200, 7)</code> \$ ightarrow\$ 200행 7열 표 데이터
<code>df.columns</code>	모든 열 이름의 목록 (Index 객체)	<code>['측정시각', '오일온도', '모터전류', ...]</code> (열 추출 키)
<code>df.index</code>	행 번호표 정보 (RangeIndex)	<code>RangeIndex(start=0, stop=200, step=1)</code> (0~199번)
<code>df.dtypes</code>	각 열의 자료형 (Data Type)	<code>int64</code> (정수), <code>float64</code> (실수), <code>object</code> (글자)

4. dtypes 점검이 중요한 이유 (자료형 문제)

PART 01. 구조 파악

| 수치 열이 object(글자)로 읽히는 경우

- 센서 수치 열에 특수문자나 공백, 텍스트 에러가 섞여 들어간 경우
- **문제점:** `mean()` 등 숫자 연산 실행 시 오류가 발생하거나 계산 불가

| ID/코드 열이 숫자(int64)로 읽히는 경우

- 우편번호, 제품 코드, 설비 ID가 숫자로 읽히는 경우
- **문제점:** 앞자리의 0이 손실됨 (예: ID 00123 $\rightarrow$ 123으로 훼손)

| ★ 핵심 습관

분석 시작 전 `df.dtypes`를 1초만 찍어보면, 수시간 동안 겪을 계산 오류를 미리 예방할 수 있습니다.

5. 종합 검진 도구: df.info()

PART 01. 구조 파악

df.info()가 보여주는 정보

- 전체 행 수 및 인덱스 범위
- 전체 열 개수 및 각 열 이름
- **Non-Null Count (결측 아닌 정상 데이터 개수)**
- 각 열의 자료형(Dtype) 및 전체 메모리 사용량

Non-Null Count로 결측 발견하기

전체 행 수(예: 200)보다 Non-Null 수치가 적다면? $\rightarrow$ 결측치 존재!

```
# df.info() 출력 예시
RangeIndex: 200 entries, 0 to 199
Data columns (total 3 columns):
#   Column      Non-Null Count  Dtype
---  -
0   오일온도     196 non-null    float64 # 결측 4개
1   모터전류     200 non-null    float64
2   가동상태     200 non-null    object
```

6. 기초 통계 요약: df.describe()

수치형(int/float) 열들의 8가지 대표 통계량을 자동으로 한 번에 계산하여 요약표를 만들어줍니다.

통계량	의미 및 수식	실무 해석 포인트
count	결측이 아닌 데이터 개수	info()의 Non-Null 수치와 동일
mean / std	평균값 (μ) 및 표준편차 (σ)	대표 중심 및 변동성/불안정성 측정
min / max	최솟값 및 최댓값	수집 수치의 최소/최고 작동 범위
25%, 50%, 75%	사분위수 (50%는 중앙값 Median)	중앙 절반의 집중 분포 구역 확인

7. describe()로 이상 신호(Outlier) 포착하기

PART 02. 통계 미리보기

75% 분위수와 max의 거리 비교

- 75% 지점과 max 수치가 서로 가깝다 $\rightarrow$ 고르게 분포된 정상 데이터
- **75% 지점과 max 수치 간격이 매우 멀다** $\rightarrow$ 상위 극단치가 존재하는 이상 신호!

설비 센서 예시 비교

- **모터전류**: 75% = 15.4A, max = 15.9A $\rightarrow$ 고른 정상 작동
- **오일온도**: 75% = 68.2 $^{\circ}\text{C}$, max = 132.5 $^{\circ}\text{C}$ $\rightarrow$ **순간 과열 이상발생 의심!**

★ 분석가적 자세

describe()는 이상치를 확정 짓는 도구가 아니라, "**어느 센서 열을 추가 조사해야 하는가?**"에 대한 첫 번째 단서를 제공하는 출발점입니다.

8. [실습 활용 예제] 데이터 탐색 4종 세트 실행

실습 가이드 참고

| 시나리오: 지하철 공기압축기 실데이터의 크기, 구조, 결측치 및 기초 통계 한 번에 탐색

```
import pandas as pd

# 1. 데이터 읽기 및 크기, 열 목록 확인
df = pd.read_csv("data/12_metro_compressor.csv")
print("데이터 크기 (shape):", df.shape) # (200, 7)

# 2. 상위 3개 행 미리보기
print(df.head(3))

# 3. 종합 검진 (info) 실행
df.info()

# 4. 수치형 열 통계 요약 (describe) 실행
print(df.describe())
```

9. 데이터 첫 탐색 체크리스트 요약

SUMMARY

1. HEAD

무엇에 관한 데이터인가?

열 이름과 실제 수집된 값
패턴 눈으로 확인

2. SHAPE

얼마나 큰 작업인가?

전체 행 수와 열 수 크기
파악

3. INFO

어디가 문제인가?

Non-Null 수치로 결측
및 자료형 점검

4. DESCRIBE

수치가 정상인가?

평균, 표준편차, 75% vs
max 간격으로 이상 포착

★ Pandas 탐색 기초 완벽 마스터! 다음 단원: 조건 슬라이싱 및 데이터 정제/전처리로 진입!