

설비 고장을 예측하는 AI 데이터 분석

이상치 처리

이상치 개념과 사분위수

C O N T E N T S

목차

- | | | |
|----|-----------------------------|--------|
| 01 | 이상치 이해 — 개념과 처리 흐름 | 개념·프레임 |
| 02 | 분포와 사분위수 — 분포 통계와 사분위수 구하기 | 개념 |
| 03 | 직접 분석 실습 — 손으로 확인하는 분포와 분위수 | 실습 |

01

이상치 이해

이상치 개념과 처리 흐름

다이캐스팅 주조 공정 이해 — 도메인 노트

데이터를 읽기 전, 이 설비가 무엇을 재는지 먼저 이해

① 공정

다이캐스팅은 녹인 금속을 고압으로 금형에 주입해 부품을 성형하는 주조 방식. 한 번의 주입을 샷이라 부른다.

② 핵심 변수

실린더압력은 금속을 밀어넣는 유압, 사이클타임은 한 샷에 걸린 시간, 비스킷두께는 잔류 금속, 형체력은 금형을 무는 힘을 뜻한다.

③ 정상과 이상

정상 샷은 사이클타임 20~35초에 압력이 일정 범위를 유지한다. 잼이나 미충전이 생기면 사이클타임이 급증하고 압력이 벗어난다.

④ 왜 이 분석

대부분이 정상이고 이상은 드물게 튜다. 그래서 사분위수와 IQR로 가운데 절반을 기준 삼아 벗어난 샷을 이상 후보로 골라낸다.

이상치란 무엇인가

다른 값들과 크게 동떨어진 값 — 설비 데이터에서는 그 자체가 고장 신호일 수 있는 대상

이상치는 다른 값들과 크게 동떨어진 값

예: 모터 온도 72·75·78도 사이에 갑자기 찍힌 250도, 진동 평소 3에 한 번 찍힌 12

설비 데이터에서는 그 자체가 고장 신호일 수 있음

발견 즉시 삭제가 아니라 멈춰서 살펴볼 대상

이상치 — 오류일까 신호일까

데이터만 보서는 단번에 못 가림 — 일단 찾아내고 그다음에 판단하는 순서

오류 가능성

센서 고장이나 입력 실수로
잘못 들어온 값

센서가 헛거워져 -5도가 찍히는 식 — 버려야 할 잡음

설비 상태와 **무관**한 값

신호 가능성

설비가 실제로 평소와
다르게 동작한 값

베어링이 닳아 진동이 커지는 식 — 가장 찾고 싶은 단서

설비가 진짜 그런 상태였던 값 — **고장 단서**

이상치가 생기는 원인

원인은 크게 두 갈래 — 측정·기록 오류와 실제 이상 동작

01 · 측정·기록 오류

**센서·통신·입력 단계에서
잘못 들어온 값**

센서 노후, 접촉 불량, 통신 끊김, 단위 혼동, 자리 입력 실수

예: 75를 750으로 입력, 섭씨를 화씨로 혼동

02 · 실제 이상 동작

**설비가 진짜로 평소를
벗어난 값**

베어링 마모, 냉각 불량, 윤활 부족으로 값이 평소를 벗어남

센서가 틀린 게 아니라 설비가 진짜 그랬다는 뜻

원인을 알면 판단이 쉬워진다

같은 250도라도 센서 오류인지 실제 과열인지는 숫자만으로 알 수 없음

POINT 01

숫자만으로는 결론 불가 — 동떨어진 값을 일단 찾아내기

POINT 02

어느 쪽인지 판단하는 단계를 따로 두기

POINT 03

원인을 미리 알면 어떤 값을 만났을 때 더 빠른 가늠 가능

노이즈 이상치와 신호 이상치

잡음은 정리, 신호는 보존 — 지우면 고장 흔적까지 함께 사라짐

노이즈성

설비 상태와 무관하게 잘못 들어온 잡음, **정리 대상**

예: 온도 -5도처럼 물리적으로 불가능한 값 — 어떤 설비도 영하로 정상 가동되지 않음

신호성

설비가 실제로 달라져 나타난 값, **고장 단서**

예: 진동 12 — 물리적으로 가능한 값이고 평소와 다를 뿐, 지우면 고장 흔적이 소실

이상치 발견 시 던질 질문

지울까 말까가 아니라 노이즈인가 신호인가를 먼저 묻기

지울까 말까가 아니라 노이즈인가 신호인가를 먼저 질문

물리적으로 불가능하면 노이즈, 가능한데 평소와 다르면 신호

판단에는 설비를 아는 도메인 지식이 함께 필요

이상치를 무조건 지우면 안 되는 이유

원칙은 발견 즉시 삭제가 아니라 발견 후 판단

고장은 평소와 다른 상태에서 발생 — 그 순간이 곧 **이상치**

다 지우면 **고장을 알려 주던 단서**까지 함께 소실

원칙은 발견 즉시 삭제가 아니라 **발견 후 판단**

발견 후 신중한 처리

노이즈는 정리, 신호로 의심되면 따로 표시 후 보존

PROCESS 01

노이즈로 확인된 것만 정리, 신호로 의심되면 보존

PROCESS 02

표시는 **이상 의심 구간** 컬럼에 1로 기록

PROCESS 03

이 한 단계가 고장을 **놓치느냐 잡느냐**를 가름

결측치 vs 이상치

값이 비었는가, 값은 있으나 동떨어졌는가가 본질적 차이

구분	결측치	이상치
상태	값이 비어 있음	값이 있으나 동떨어짐
표시	NaN	채워진 숫자 (예: 250)
찾는 법	isna()	isna()로 못 찾음

이상치는 비어 있지 않아 isna로 못 찾음 — 얼마나 동떨어졌는지를 따져야 함

결측치와 이상치는 처리에서 이어진다

찾는 법은 달라도 처리 단계에서는 서로 손을 잡는 사이

PROCESS 01

이상치 처리의 한 방법이 그 값을 NaN으로 바꾼 뒤 채우기

PROCESS 02

믿을 수 없는 값을 일단 비우고 주변 값으로 메우기

PROCESS 03

찾는 법은 달라도 처리 단계에서는 서로 손을 잡는 사이

이상치가 평균을 왜곡한다

70도대 데이터에 250·300이 섞이면 평균이 115까지 치솟음

지표	값	해석
평균	약 115.6도	이상치에 끌려 올라감 — 큰 값이 합계를 위로 당김
중앙값	76.5도	실제 분위기 — 양 끝값에 흔들리지 않음
표준편차	약 90.5	비정상적으로 큼 — 현실과 동떨어진 값

평균을 평소 온도라고 잘못 받아들이면 정상 범위와 경고 기준이 모두 틀어짐

평균-중앙값 격차는 이상치 신호

두 값을 항상 나란히 확인하는 작은 습관 하나가 큰 오해를 막음

중앙값은 가운데 값이라 양 끝 이상치에 거의 흔들리지 않음

평균 115 vs 중앙값 76.5 — 큰 격차 자체가 이상치 신호

데이터를 받으면 두 값을 항상 나란히 확인

정상 범위와 이상 범위

이상치를 찾는다는 것은 정상 범위의 경계선을 긋는 일

01 · 경계 긋기

아래쪽 **하한**과 위쪽 **상한** 사이가 정상, 바깥이 이상

02 · 예시

정상을 **60~90도**로 정하면 **250도**와 **-5도**는 자동으로 이상

03 · 핵심

동떨어졌다고 말하려면 **먼저 보통의 범위**를 정해야 함

범위를 정하는 두 방법

오늘 배우는 IQR이 자동 계산 방식의 대표

01 · 수동 지정

현장 전문가가
정상 범위 직접 지정

가장 믿을 만하나 컬럼이 많으면 비현실적

전문가 지식 기반 · 도메인 의존

02 · 자동 계산

데이터의 가운데 절반을
기준으로 경계 결정

컬럼이 많아도 한 번에 적용 — 오늘 배울 IQR 방식

분포 기반 · 데이터 스스로의 경계

이상치를 찾는 세 가지 접근

세 방법은 경쟁이 아니라 상황 따라 함께 쓰는 도구

01 · 눈으로

사람이 직접 훑어 찾기

표나 그래프를 사람이
직접 훑어 찾기

데이터가 적을 때 충분

감각 훈련 · 검증의 기준

02 · 통계로

분포를 계산해 자동 선별

분포 계산으로
기준 넘는 값 자동 선별

오늘 배울 **IQR**이 대표

자동·일관·대량 컬럼 가능

03 · 모델로

패턴 학습으로 판단

패턴을 학습시켜
평소와 다른 데이터 판단

이후 학습에서 다룰 머신러닝 영역

여러 센서 동시 분석

오늘의 위치 — 통계 기반 IQR

IQR을 이해하려면 분포 읽기가 먼저

세 접근 중 **통계 기반**, 그중 가장 기본인 **IQR**을 학습

IQR을 쓰려면 **데이터 분포**를 숫자로 읽는 법이 먼저

세 방법은 경쟁이 아니라 **상황 따라 함께 쓰는 도구**

이상치 처리 3단계 흐름

탐색 → 판단 → 처리, 세 단계의 흐름

STEP 1

탐색

동떨어진 값의 위치를 찾아냄. 오늘의 **IQR**이 담당

자동 위치 탐색



STEP 2

판단

노이즈인지 신호인지 결정. **도메인 지식** 필요

가장 중요·어려운 단계



STEP 3

처리

제거·보정·결측 변환. 신호는 **보존**

판단 결과 따라 처리

탐색은 자동, 판단은 사람·도메인, 처리는 결과에 따라 — 세 단계를 분리해 생각하는 일이 핵심

흐름의 핵심 — 판단을 건너뛰지 않기

가장 중요한 것은 판단 단계를 생략하지 않기

처리는 항상 **지우기**가 아니라 **남기거나 바꿀지 결정**하는 일

노이즈는 정리, 신호는 보존 — **같은 이상치도 다르게 처리**

가장 중요한 것은 **판단 단계를 생략하지 않기**

처리는 반복되고 기록된다

일회성 작업이 아니라 꾸준한 관리 활동에 가까움

POINT 01

한 번 하고 끝이 아니라 데이터가 쌓일 때마다 반복

POINT 02

무엇을 왜 노이즈로 또는 신호로 판단했는지 기록이 중요

POINT 03

기록이 있어야 다른 사람도 이해하고 판단 근거를 되짚을 수 있음

02

분포와 사분위수

분포 통계와 사분위수 구하기

데이터를 보는 두 축

이상치는 바로 퍼짐의 바깥 끝에 있음

01 · 중심

데이터가 대체로
어디에 모였나

대표 지표: 평균, 중앙값

보통 어느 정도냐는 질문에 답하는 숫자

02 · 퍼짐

중심에서 얼마나
흩어졌나

대표 지표: 범위, 표준편차, IQR

이상치는 이 퍼짐의 바깥 끝에 위치

같은 평균, 다른 퍼짐

중심과 퍼짐을 반드시 함께 봐야 데이터를 제대로 이해

설비 A · 안정

평균 75도 · 범위 73~77도

좁은 폭으로 모여 있음 — 평소대로 안정적으로 가동 중

설비 B · 불안정

평균 75도 · 범위 50~100도

넓게 흩어져 있음 — 무언가 불안정한 상태

중심만 보면 같은 설비 — 퍼짐을 정확히 재는 일이 곧 이상치를 잘 찾는 길

이상치에 강한 도구를 쓰자

흔들리는 자로 흔들리는 대상을 재면 기준이 무너짐

관점	✖ 이상치에 약한 값	✔ 이상치에 강한 값
중심	평균	중앙값
퍼짐	범위 · 표준편차	IQR

250·300 석이면 평균 115·표준편차 90 — 중앙값 76.5, IQR은 가운데 절반 폭으로 안정적

최소·최대·범위 읽기

범위 = 최댓값 - 최솟값, 데이터가 퍼진 폭을 한 숫자로 표현

01 · 함수

min은 최솟값, **max**는 최댓값을 한 줄로 계산

02 · 정의

범위 = **최댓값 - 최솟값**, 퍼진 폭을 한 숫자로 표현

03 · 예시

온도 최소 **-5도**, 최대 **300도** → 범위 **305도**

범위의 약점

양 끝만 보니 이상치 하나에 완전히 휘둘림

범위는 **양 끝 두 값**만으로 계산 → 이상치 하나에 완전히 휘둘림

300도 하나만 있어도 범위가 305도로 확 커짐

그래서 가운데를 보는 **사분위수와 IQR**로 넘어감

평균과 중앙값의 차이

가운데 사람을 보느냐, 모든 값을 더하느냐의 차이

평균

모든 값을 더해 나눔, 큰 값에 끌려 **이상치에 약함**

300이 끼면 그대로 합계를 위로 당김 — 값 하나하나가 결과에 직접 더해짐

중앙값

크기순 가운데 값, 양 끝 값 무시해 **이상치에 강함**

300이 3000으로 커져도 가운데 사람은 그대로 — 흔들리지 않음

이상치 앞에서 무엇을 믿나

사분위수는 중앙값 사고방식을 확장한 것

평균이 실제 분위기와 다르면 **이상치에 끌려간 것**

이럴 때는 **중앙값**이 진짜 중심을 더 정확히 알려 줌

사분위수는 이 중앙값 사고방식을 확장한 것

중앙값 다시 보기

값을 크기순으로 정렬한 뒤 한가운데 값을 고르는 방식

STEP 01 · 정렬

값을 **크기순으로 정렬**한 뒤 한가운데 값을 고르기

STEP 02 · 홀수·짝수

홀수면 **가운데 하나**, 짝수면 **가운데 두 값의 평균**

STEP 03 · 주의

구하기 전 **반드시 정렬** — 안 하면 엉뚱한 값이 가운데에 옴

중앙값에서 사분위수로

절반 나누기에서 네 등분 나누기로 확장한 것이 사분위수

중앙값은 데이터를 **절반**으로 나누는 선

절반이 아니라 **네 등분**하면 경계선이 **세 개**

그 세 선이 바로 **사분위수** (Q1, Q2, Q3)

사분위수란 무엇인가

Q1·Q2·Q3 — 데이터를 크기순 네 등분하는 세 경계값

Q1

25%

1사분위수

전체의 **4분의 1 지점** — 이 값보다 작은 데이터가 25%

Q2 · 중앙값

50%

2사분위수 = 중앙값

가운데 지점 — 중앙값과 동일한 값

Q3

75%

3사분위수

전체의 **4분의 3 지점** — Q1~Q3 사이에 가운데 절반

우리 데이터의 사분위수

이상치가 섞여도 사분위수는 가운데만 보기 때문에 거의 흔들리지 않음

Q1

74도

전체의 4분의 1이 74도보다 작음

Q3

81.5도

전체의 4분의 3이 81.5도보다 작음

가운데 절반

74~81.5

이 사이에 보통의 온도값이 모여 있음

평균 115에 비하면 든든한 기준

백분위수와 사분위수

백분위수가 큰 개념, 사분위수는 그중 25·50·75만 골라낸 좁은 개념

01 · 백분위수

데이터를 100등분한 지점, 90백분위수면 90%가 그보다 작음

02 · 사분위수

그중 25·50·75퍼센트 세 지점에 이름을 붙인 것

03 · quantile 인자

quantile 괄호 숫자가 바로 이 비율 — 25%는 0.25

quantile 괄호 숫자의 의미

퍼센트를 100으로 나눈 소수를 괄호에 넣기

Q1은 0.25, Q2는 0.5, Q3는 0.75


퍼센트를 100으로 나눈 소수를 괄호에 넣는다고 기억

0.9를 넣으면 90백분위수, 0.99면 상위 1% 경계

박스플롯으로 보는 사분위수

상자는 가운데 절반, 상자 속 선은 중앙값, 수염 밖 점은 이상치

BOXPLOT



읽는 법

상자 = Q1~Q3 (가운데 절반)

74에서 81.5에 얇게 자리 잡음

상자 속 선 = 중앙값

데이터의 정중앙 76.5

수염 밖 점 = 이상치

250, 300, -5 — 한눈에 보임

박스플롯은 IQR을 그린 것

오늘은 그리기가 아니라 읽기에 집중

박스플롯의 이상치 기준이 곧 **IQR 규칙과 동일**

오늘은 그리기가 아니라 읽기에 집중 — 그리기는 이후 학습에서

상자는 **가운데 절반**, 수염 밖 점은 **이상치**라는 읽기만 익히기

quantile()로 사분위수 구하기

컬럼 뒤에 점 찍고 quantile, 괄호에 비율을 넣기

CODE

```
# Q1 = 25%, Q2 = 50% (= 중앙값), Q3 = 75%
Q1 = df["temperature"].quantile(0.25)
Q2 = df["temperature"].quantile(0.5)
Q3 = df["temperature"].quantile(0.75)
print(Q1, Q2, Q3)

# 결과: 74.0 76.5 81.5
```


quantile 한 번에 구하기와 주의점

quantile 인자는 비율 — 반드시 0과 1 사이 소수

CODE

```
# 대괄호로 묶어 세 값 한 번에
print(df["temperature"].quantile([0.25, 0.5, 0.75]))

# 결과:
# 0.25 74.0
# 0.50 76.5
# 0.75 81.5
```

자주 하는 실수

25·50·75를 넣는 경우 — quantile 인자는 반드시 0~1 소수. 25를 넣으면 오류

describe()로 분포 한눈에

개수·평균·표준편차·최소·사분위수·최대를 한 번에 — 데이터를 받자마자 가장 먼저

CODE

```
# 분포 요약 통계를 한 번에
print(df["temperature"].describe())

# count 18.000000
# mean 115.611111
# std 90.500000
# min -5.000000
# 25% 74.000000
# 50% 76.500000
# 75% 81.500000
# max 300.000000
```

describe 읽는 법

청진기처럼 데이터 건강을 빠르게 진단해 주는 함수

항목	값	읽기
mean	115.6	이상치에 끌려 높음 — 실제 분위기 아님
50%	76.5	실제 분위기 (중앙값) — 평균과 큰 격차
min / max	5 / 300	양쪽 모두 비현실적 — 사분위수에서 멀리 벗어남

평균-중앙값 큰 격차 = 이상치 신호, 양 끝값이 사분위수에서 멀면 비현실적 값 존재

예지보전 속 이상치 처리

예지보전의 출발점이자 토대는 전처리

01 · 예지보전

데이터로 **고장을 미리 알아채** 대비하는 일

02 · 출발점

그 출발점이자 토대가 데이터를 깨끗이 하는 **전처리**

03 · 오늘의 위치

오늘 배우는 **결측치·이상치 처리**가 모두 전처리에 속함

좋은 데이터가 좋은 모델을 만든다

노이즈는 정리하되 신호는 보존 — 오늘의 원칙이 빛을 발하는 자리

노이즈를 두면 모델이 **센서 오류**를 학습

신호를 다 지우면 모델이 **고장 단서**를 못 봄

실제 제조 연구도 **사분위수로 찾아 중앙값 대체**하는 흐름

03

직접 분석 실습

손으로 확인하는 분포와 분위수

실습 1. 주조 데이터 구조·분포 살펴보기

다이캐스팅 설비 데이터를 불러와 구조를 첫 진단

목표

주조 데이터를 불러와 크기·컬럼·자료형을 확인

단계

- read_csv로 데이터를 불러와 head로 앞부분 확인
- shape와 columns로 크기와 컬럼 이름 확인
- info로 자료형과 결측 여부 훑기

예상 결과

202행 7열, 실린더압력·사이클타임 등 컬럼 확인

실습 2. 한 컬럼의 최소·최대·범위

실린더압력의 양 끝값과 범위로 퍼짐 확인

목표

한 컬럼의 최솟값·최댓값·범위를 구해 퍼짐 확인

단계

- 실린더압력 열의 최솟값 구하기
- 실린더압력 열의 최댓값 구하기
- 최댓값에서 최솟값을 빼 범위 계산

예상 결과

실린더압력 최소 108·최대 265·범위 157

실습 3. 정렬해서 이상치 후보 찾기

정렬로 동떨어진 사이클타임을 눈으로 찾아 분류

목표

정렬해 양 끝의 동떨어진 값을 후보로 찾고 분류

단계

- 사이클타임 열을 기준으로 내림차순 정렬
- 위쪽 끝에서 동떨어진 큰 값 찾기
- 각 후보를 정상 상태와 이상 상태로 나누기

예상 결과

6170·652초 등 설비 잦 후보, 정상은 20~35초

실습 4. 평균·중앙값으로 이상치 영향 확인

이상치가 평균을 끌어당기는 정도를 중앙값과 비교

목표

이상치가 평균을 끌어당기는 정도를 중앙값과 비교

단계

- 사이클타임의 평균과 중앙값을 각각 구해 차이 확인
- 상태가 정상인 행만 조건으로 골라내기
- 정상만의 평균이 중앙값에 가까워지는지 확인

예상 결과

평균 64.75 vs 중앙값 22.6, 정상만 평균 27.67

실습 5. quantile로 Q1·Q2·Q3

실린더압력의 사분위수를 구하고 Q2와 중앙값 일치 확인

목표

사분위수를 구하고 Q2가 중앙값과 같은지 확인

단계

- 25% 지점 값을 quantile로 구해 Q1 확인
- 50% 지점 값이 중앙값과 같은지 확인
- 75% 지점 값을 구해 가운데 절반 범위 파악

예상 결과

실린더압력 Q1 215.75·Q2 218·Q3 265

실습 6. describe로 격차 큰 컬럼 찾기

describe 표에서 평균-중앙값 격차 큰 이상치 의심 컬럼 찾기

목표

describe 표에서 이상치 의심 컬럼을 찾아 해석

단계

- 여러 공정 컬럼을 describe로 요약
- 요약을 컬럼별로 정리하고 평균과 중앙값 격차 계산
- 격차가 큰 순으로 정렬해 이상치 의심 컬럼 확인

예상 결과

주조압력.형체력.사이클타임 등 격차 큰 컬럼 확인

실습 7. 여러 컬럼의 가운데 절반 폭 비교

세 컬럼의 Q3-Q1을 비교해 안정·의심 컬럼 구분

목표

세 컬럼의 가운데 절반 폭(Q3-Q1)을 비교

단계

- 세 컬럼의 사분위수를 한 번에 구하기
- 각 컬럼의 75% 값에서 25% 값을 빼 가운데 절반 폭 계산
- 폭이 좁은 안정 컬럼과 넓은 의심 컬럼 구분

예상 결과

폭 실린더압력 49.25·사이클타임 15.12·비스킷두께 6